

ĐẠI HỌC QUỐC GIA HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO
ĐỒ ÁN TỐT NGHIỆP
Học Kỳ 2 2025-2026

XÂY DỰNG MÔ HÌNH TỰ ĐỘNG PHÁT HIỆN CÁC
LỚP ĐỐI TƯỢNG MỚI TRONG PHÂN LOẠI ẢNH SỬ
DỤNG BIỂU DIỄN ĐẶC TRƯNG SÂU

CHUYÊN NGÀNH: KHOA HỌC MÁY TÍNH

GVHD1: Assoc. Prof Lê Hồng Trang Ph.D

GVHD2: Dương Đức Tín MEng

—o0o—

SINH VIÊN 1: NGUYỄN CHÂU KIỆT - 2113845

SINH VIÊN 2: LÂM SƠN TÙNG - 2112612

THÀNH PHỐ HỒ CHÍ MINH, 05/2026

Chữ Ký Giảng Viên

_____ Ngày: _____

Tên Giảng Viên :

...

Khoa Khoa Học và Kỹ Thuật Máy Tính

Lời cam đoan

Chúng tôi xin cam đoan đây là nền tảng do nhóm tự nghiên cứu và phát triển dưới sự hướng dẫn của Assoc. Prof Lê Hồng Trang Ph.D và Dương Đức Tín MEng. Các nội dung nghiên cứu, kết quả đề tài là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây.

Nếu có phát hiện bất kỳ gian lận nào, chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung và chấp nhận mọi hình thức kỷ luật trước Ban chủ nhiệm Khoa Khoa Học Và Kỹ Thuật Máy Tính và Ban Giám Hiệu Trường Đại Học Bách Khoa, ĐHQG Thành Phố Hồ Chí Minh.

Thành Phố Hồ Chí Minh, 05/2026

Tác giả,

Nguyễn Châu Kiệt

Lâm Sơn Tùng

Lời cảm ơn

Chúng em xin gửi lời cảm ơn chân thành đến Assoc. Prof Lê Hồng Trang Ph.D và Dương Đức Tín MEng, hai người đã tận tình hướng dẫn, hỗ trợ và đưa ra các góp ý quý báu để chúng em hoàn thành đồ án này. Cảm ơn hai thầy đã góp ý cho chúng em nhiều ý kiến hữu ích, tạo điều kiện về cơ sở vật chất để chúng em thực hiện đề tài. Trong suốt quá trình thực hiện, hai thầy đã hướng dẫn chúng em về quy trình làm việc, cung cấp cho chúng em nhiều tài liệu tham khảo bổ ích, đánh giá về những ý tưởng cũng như khả năng hiện thực, giúp chúng em vượt qua được những khó khăn để có được kết quả cuối cùng này.

Chúng em cũng xin bày tỏ lòng biết ơn đến các thầy cô của Khoa Khoa Học và Kỹ Thuật Máy Tính, Trường Đại học Bách Khoa, vì đã truyền đạt những kiến thức nền tảng và chuyên sâu trong suốt thời gian học tập tại trường. Những kiến thức ấy đã trở thành hành trang quý giá, giúp chúng em áp dụng vào việc nghiên cứu và triển khai hệ thống.

Đồng thời, chúng em xin cảm ơn gia đình và bạn bè, những người đã luôn ủng hộ, động viên và tạo điều kiện tốt nhất để chúng em có thể tập trung hoàn thành đồ án này.

Cuối cùng, vì thời gian và năng lực còn hạn chế, chúng em khó tránh khỏi những thiếu sót trong quá trình thực hiện. Chúng em rất mong nhận được những ý kiến đóng góp từ quý thầy cô và bạn bè để đồ án này được hoàn thiện hơn.

Xin chân thành cảm ơn!

Nhóm thực hiện đồ án

Tóm tắt

Trong thế giới mở, không phải mọi dữ liệu đều được gán nhãn để mô hình có thể học và phân loại theo cách truyền thống. Khám phá lớp mới nhằm xác định các lớp mới trong tập dữ liệu chưa gán nhãn bằng việc tận dụng các tri thức đã có từ các lớp đã biết. Bài toán này xuất hiện và có nhiều ứng dụng trong thực tế. Ứng dụng đầu tiên phải kể đến đó là việc thực hiện gán nhãn dữ liệu tự động, giúp giảm được một lượng chi phí lớn cho việc này hay việc phân loại các sản phẩm mới trong siêu thị hiện nay được làm thủ công, thì việc tự phát hiện và phân loại tự động cũng trở nên hữu ích. Trong công sản xuất, việc giám sát ngoại quan các lỗi sản phẩm cũng thường xuyên gặp những lỗi mới hay những biến thể mới của các lỗi đã có. Việc thu thập dữ liệu, gán nhãn và huấn luyện lại các mô hình cho những trường hợp này sẽ mất rất nhiều thời gian và chi phí. Đề tài này tập trung nghiên cứu bài toán khám phá lớp mới và các tiếp cận hiệu quả hiện nay để giải. Các phương pháp nghiên cứu sẽ được thực nghiệm trên cả các bộ dữ liệu chuẩn cũng như dữ liệu thu thập thực tế, nhằm đánh giá kết quả của các mô hình đề xuất.

Yêu cầu :

- Tìm hiểu về bài toán Novel Class Discovery (NCD), các ứng dụng.
- Tìm hiểu và nghiên cứu các phương pháp được đề xuất ở những công trình trước.
- Thực nghiệm với một số tiếp cận liên quan đến sử dụng kỹ thuật học đặc trưng sâu.
- Phân tích kết quả đạt được và đề xuất sơ bộ một cải thiện hay kiến trúc mới.

Bảng thuật ngữ

1. **GCD (Generalized Category Discovery):** Bài toán khám phá danh mục tổng quát, yêu cầu mô hình vừa phân loại chính xác các lớp đã biết (Known/Old), vừa tự động gom cụm và khám phá các lớp mới (Unknown/New) từ dữ liệu không nhãn.
2. **OOD (Out-of-Distribution):** Dữ liệu nằm ngoài phân phối của tập huấn luyện gốc. Trong ngữ cảnh GCD, OOD đại diện cho các mẫu hình ảnh thuộc về danh mục hoàn toàn mới.
3. **SNC (Selective Neighbor Clustering):** Thuật toán phân cụm phân cấp dựa trên đồ thị láng giềng gần nhất (1-NN), kế thừa từ FINCH. SNC xây dựng các phân hoạch từ thô đến mịn và cho phép tích hợp anchor constraints để chuyển sang chế độ bán giám sát.
4. **GEN (Generalized Entropy):** Điểm số phát hiện dữ liệu ngoài phân phối dựa trên entropy tổng quát của phân phối xác suất Softmax. GEN chỉ xét Top- M xác suất cao nhất với hệ số sắc nét γ , giúp phân biệt mẫu Known (GEN thấp) và Unknown (GEN cao).
5. **Pseudo-label (Nhãn giả):** Nhãn được mô hình tự động gán cho dữ liệu chưa có nhãn dựa trên các dự đoán có độ tin cậy cao, đóng vai trò quan trọng trong quá trình học bán giám sát.
6. **Anchor (Điểm neo):** Các mẫu dữ liệu đại diện tiêu biểu cho một danh mục, được sử dụng làm mốc tham chiếu để dẫn dắt quá trình gom cụm (áp dụng trong cơ chế

phân cụm SNC).

7. **Entropy:** Thước đo toán học dùng để định lượng độ bất định hoặc sự phân tán của một phân phối xác suất. GEN sử dụng Generalized Entropy để nhận diện dữ liệu OOD.
8. **Logits:** Các giá trị đầu ra thô chưa qua chuẩn hóa của lớp cuối cùng trong mạng nơ-ron trước khi được tính toán qua hàm Softmax.
9. **Features (Đặc trưng):** Các vector biểu diễn số học (như CLS token) được trích xuất từ dữ liệu đầu vào thông qua mạng học sâu (ViT DINO), đóng vai trò tính toán sự tương đồng giữa các ảnh.
10. **Overconfidence (Tự tin thái quá):** Hiện tượng mạng nơ-ron gán xác suất cực kỳ cao cho một danh mục cũ ngay cả khi đối mặt với dữ liệu ngoài phân phối, gây nhiễu loạn bộ lọc nhãn giả.
11. **Truncation / Clipping (Cắt tỉa / Chặn ngưỡng):** Kỹ thuật loại bỏ các giá trị dự đoán có xác suất thấp nhằm khử nhiễu ở đuôi phân phối (trong thuật toán GEN) hoặc giới hạn các giá trị kích hoạt quá lớn (trong thuật toán React).
12. **H-score:** Trung bình điều hòa giữa độ chính xác phân loại của tập lớp cũ (Old ACC) và tập lớp mới (New ACC), thước đo đánh giá năng lực cân bằng tổng thể của một hệ thống GCD.
13. **Transductive Learning :** Giao thức học và đánh giá mà trong đó mô hình được phép truy cập đặc trưng (nhưng không được biết nhãn) của toàn bộ dữ liệu kiểm tra ngay trong quá trình gom cụm, nhằm khai thác cấu trúc phân phối tổng cục.
14. **Catastrophic Forgetting:** Hiện tượng mô hình bị suy giảm nghiêm trọng độ chính xác trên các danh mục cũ (Known) sau khi tập trung tinh chỉnh để khám phá các

danh mục mới (Unknown).

Mục lục

Bảng thuật ngữ	v
Khai báo Công cụ Hỗ trợ	1
Danh mục từ viết tắt	2
1 Giới thiệu	3
1.1 Bối cảnh và Động lực Nghiên cứu	3
1.2 Đóng góp của Luận văn	5
1.3 Phạm vi và Giới hạn	6
1.4 Cấu trúc Luận văn	7
2 Tổng quan Nghiên cứu Liên quan	9
2.1 Self-supervised learning và Vision Transformer DINO	9
2.1.1 Học tương phản và các kỹ thuật SSL tiêu biểu	9
2.1.2 Kiến trúc Vision Transformer (ViT)	11
2.1.3 DINO	12
2.2 Phát hiện ngoài phân phối (OOD Detection)	13
2.2.1 Softmax và Maximum Softmax Probability	13
2.2.2 Cải tiến Energy-based Score	14
2.2.3 Generalized Entropy	15
2.2.4 Adaptive Thresholding	17
2.2.5 Nhận xét	18
2.3 Khám phá Danh mục Tổng quát (Generalized Category Discovery - GCD)	18

2.3.1	Định nghĩa hình thức bài toán GCD	18
2.3.2	Tiến trình phát triển từ NCD đến GCD	19
2.3.3	Cơ chế học biểu diễn tương phản trong GCD	20
2.3.4	Các phương pháp GCD nổi bật và Bảng so sánh	20
2.4	Framework CiPR và Thuật toán Selective Neighbor Clustering (SNC) .	21
2.4.1	Cross-instance Positive Relations	22
2.4.2	Thuật toán Selective Neighbor Clustering (SNC)	23
2.4.3	Phân tích hiệu năng và so sánh thực nghiệm	24
2.4.4	Giới hạn của CiPR và động lực phát triển GESNC	24
2.5	Semi-supervised learning và Pseudo-labeling	25
2.5.1	Gom cụm semi-supervised dựa trên ràng buộc	25
2.5.2	Chiến lược Giả nhãn (Pseudo-labeling) và sự tiến hóa của hàm mục tiêu	27
2.5.3	Tiếp cận GESNC: Lọc giả nhãn bằng Generalized Entropy (GEN)	28
2.6	Tổng hợp và Định vị Nghiên cứu	29
3	Phương pháp Đề xuất: GESNC	32
3.1	Tổng quan Kiến trúc	32
3.2	Giai đoạn 1 — Trích xuất Đặc trưng	35
3.2.1	Tiền xử lý ảnh	35
3.2.2	GCD Split Protocol	35
3.2.3	Trích xuất CLS Token	36
3.3	Giai đoạn 2 — Linear Classifier Head	36
3.3.1	Kiến trúc và Huấn luyện	36
3.3.2	Inference trên toàn bộ Dataset	37
3.3.3	Vai trò trong Pipeline	37
3.4	Giai đoạn 2b — React Feature Clipping	38
3.4.1	Vấn đề Overconfidence của Softmax	38

3.4.2	Cơ chế React	38
3.4.3	Tác động lên phân phối GEN Score	39
3.5	Giai đoạn 3 — Cổng GEN Entropy và Pseudo-labeling	39
3.5.1	Công thức GEN Score	39
3.5.2	Chọn tham số M và γ	40
3.5.3	Ngưỡng thích nghi τ	41
3.5.4	Sinh Pseudo-labels (Đóng góp mới)	42
3.6	Giai đoạn 4 — Semi-supervised SNC	44
3.6.1	Chuẩn hóa L2	44
3.6.2	Xây dựng Đồ thị 1-NN	44
3.6.3	Inject Semi-supervised Constraints (Đóng góp mới)	44
3.6.4	Graph Propagation và Connected Components	45
3.6.5	Partition Hierarchy	45
3.6.6	Điều chỉnh về K Clusters	46
3.7	Giai đoạn 5 — Đánh giá: Hungarian Matching	48
3.7.1	Bài toán gán nhãn tối ưu	48
3.7.2	Các chỉ số đánh giá	48
3.8	Phân tích độ phức tạp tính toán	49
3.9	Tóm tắt Pipeline	51
4	Thực nghiệm và Đánh giá	52
4.1	Thiết lập Thực nghiệm	52
4.1.1	Tập dữ liệu	52
4.1.2	Môi trường Triển khai	53
4.1.3	So sánh Điều kiện Thực nghiệm với CiPR	54
4.1.4	Siêu tham số	55
4.1.5	Hai Protocol Đánh giá	55
4.2	Kết quả trên CIFAR-100	56

4.2.1	So sánh với Baseline CiPR	56
4.2.2	Kết quả trên Test Set CIFAR-100	58
4.3	Phân tích Ablation — CIFAR-100	59
4.3.1	Ablation 1 — Ảnh hưởng của PCT (Pseudo-label Threshold) . .	59
4.3.2	Ablation 2 — Ảnh hưởng của React Feature Clipping	60
4.3.3	Ablation 3 — Grid Search M và γ	60
4.4	Kết quả trên CUB-200-2011	61
4.4.1	Strict Train-only — PCT Sweep	61
4.4.2	Ảnh hưởng của React trên CUB-200-2011	62
4.4.3	Kết quả Transductive trên CUB-200-2011	63
4.5	Phân tích Định tính	65
4.5.1	Phân tích Trường hợp Thất bại	67
4.6	Thảo luận	69
4.6.1	Vai trò của React trong GEN Pseudo-labeling	69
4.6.2	Trade-off Old/New ACC và Hành vi PCT	69
4.6.3	Khoảng cách CIFAR-100 và CUB-200	70
4.6.4	Giới hạn và Hướng Cải thiện	71
5	Kết luận và Hướng Phát triển	72
5.1	Tóm tắt Đóng góp	72
5.2	Hạn chế	74
5.3	Hướng Phát triển Tương lai	75
5.3.1	Ưu tiên 1 — Auto-K: Ước lượng Số Cluster Tự động	75
5.3.2	Ưu tiên 2 — Iterative Pseudo-label Refinement	75
5.3.3	Ưu tiên 3 — Mở rộng sang Dataset Lớn hơn	76
5.3.4	Ưu tiên 4 — Memory-Efficient SNC	76
5.3.5	Ưu tiên 5 — Backbone Fine-tuning Aware của GCD	76
5.4	Kết luận	77

Tài liệu tham khảo	78
A Mã nguồn Pipeline GCD_GESNC	81

Danh sách bảng

2.1	So sánh các phương pháp GCD tiêu biểu trên tập dữ liệu CIFAR-100 . .	21
2.2	So sánh hiệu năng giữa CiPR [8] và GCD [4] trên các tập dữ liệu (All ACC, %)	24
2.3	Ma trận so sánh các thành phần kỹ thuật giữa các phương pháp GCD . .	31
3.1	Bảng ký hiệu toán học và giá trị thực nghiệm	34
3.2	Phân tích độ phức tạp tính toán của GESNC	50
3.3	Tóm tắt 5 giai đoạn pipeline GESNC	51
4.1	Thống kê hai tập dữ liệu theo GCD split protocol	53
4.2	Môi trường và cấu hình thực nghiệm	53
4.3	So sánh điều kiện thực nghiệm giữa CiPR [8] và GESNC trên CIFAR-100	54
4.4	Siêu tham số của pipeline GESNC trên hai dataset	55
4.5	Baseline reproduction CiPR và cấu hình GESNC single-run tốt nhất trên CIFAR-100	57
4.6	Đánh giá đa hạt giống trên CIFAR-100 (mean $\pm$ standard deviation) . .	57
4.7	Grid search M và γ trên Test Set CIFAR-100 (PCT=10, React $q=0.99$, protocol transductive)	58
4.8	Ablation PCT trên CIFAR-100 với baseline CiPR thống nhất và các dòng PCT > 0 từ kết quả single-run mới	59
4.9	Grid search M và γ — unlabeled train, protocol transductive (CIFAR-100, PCT=10, React $q=0.99$)	61
4.10	PCT sweep — strict train-only, CUB-200-2011 ($M = 8$, $\gamma = 0.1$, no React)	62

4.11	So sánh GEN vs GEN+React — strict train-only, CUB-200-2011, PCT=15	62
4.12	Kết quả transductive (train+test) — CUB-200-2011 ($M = 8, \gamma = 0.1$).	
	Đơn vị: %	63
4.13	Đánh giá đa hạt giống trên CUB-200-2011	64

Danh sách hình vẽ

2.1	Phân cấp các bài toán phát hiện dữ liệu ngoài phân phối. GCD nằm trong nhánh Multi-Class Novelty Detection kết hợp với khả năng nhận diện lớp cũ.	17
3.1	Sơ đồ luồng xử lý toàn diện của hệ thống GESNC qua 9 giai đoạn (Phases).	33
4.1	Phân phối GEN score của Known và Unknown classes trên CIFAR-100. Đường đứt nét màu đỏ thể hiện ngưỡng τ tại PCT=10%. Có thể thấy các mẫu Known tập trung ở vùng GEN thấp (phân phối nhọn), trong khi Unknown bị đẩy về vùng GEN cao.	65
4.2	Biểu diễn t-SNE của 10.000 mẫu test CIFAR-100. (a) Màu sắc thể hiện ground-truth (Known vs Unknown). (b) Màu sắc thể hiện phân vùng cụm bởi thuật toán SNC. SNC phân cụm các Known classes rất tốt và bảo toàn cấu trúc của Unknown classes.	66
4.3	Phân phối Cluster Purity trên 100 clusters của CIFAR-100. Phần lớn các cụm có độ tinh khiết rất cao ($> 80\%$), chứng tỏ thuật toán ghép cặp (Hungarian matching) hoạt động trên các cụm đồng nhất.	67
4.4	Ma trận nhầm lẫn giữa 20 lớp Unknown và 25 lớp Known bị nhầm nhiều nhất.	68
4.5	Độ chính xác theo từng lớp Unknown trên CIFAR-100.	68

List of Algorithms

1	GEN Gate và Pseudo-label Generation	43
2	Semi-supervised SNC (GESNC)	47

Khai báo Công cụ Hỗ trợ

Trong quá trình thực hiện luận văn, nhóm tác giả có sử dụng các công cụ hỗ trợ như ChatGPT/Gemini/Claude để kiểm tra diễn đạt, rà soát văn phong kỹ thuật và hỗ trợ định dạng LaTeX. Các công cụ này không được sử dụng để sinh kết quả thực nghiệm. Một số công cụ hỗ trợ lập trình như GitHub Copilot có thể được dùng cho các đoạn tiện ích phụ trợ như xử lý dữ liệu hoặc trực quan hóa. Toàn bộ thiết kế pipeline, lựa chọn thực nghiệm, phân tích kết quả và kết luận khoa học do nhóm tác giả kiểm chứng và chịu trách nhiệm.

Danh mục từ viết tắt

Từ viết tắt	Giải thích
GCD	Generalized Category Discovery
OOD	Out-of-Distribution
GEN	Generalized Entropy
SNC	Selective Neighbor Clustering
ViT	Vision Transformer
DINO	Self-Distillation with NO labels
CiPR	Cross-instance Positive Relations
ACC	Accuracy
ANN	Approximate Nearest Neighbor
SSL	Self-Supervised Learning
NCD	Novel Category Discovery
KNN	K-Nearest Neighbors

CHƯƠNG 1

Giới thiệu

1.1 Bối cảnh và Động lực Nghiên cứu

Trong những năm gần đây, lượng dữ liệu hình ảnh được thu thập từ thế giới thực tăng lên với tốc độ chóng mặt. Phần lớn dữ liệu này tồn tại ở dạng không có nhãn, và điều quan trọng hơn là chúng thường chứa các mẫu thuộc những lớp đối tượng chưa biết trong quá trình huấn luyện. Đây là một thực tế phổ biến trong các hệ thống triển khai ngoài thực tế, nơi mà giả định tập test chỉ chứa các lớp đã biết của phân loại truyền thống [1], [2] không còn đứng vững.

Để đối phó với hạn chế trên, cộng đồng nghiên cứu đã lần lượt đề xuất nhiều hướng tiếp cận: từ Open-Set Recognition (nhận diện mẫu ngoài phân phối nhưng không phân loại chúng), đến Zero-Shot Learning (phân loại lớp mới thông qua mô tả ngữ nghĩa), và Novel Category Discovery (NCD) [3] — khám phá lớp mới trong tập unlabeled nhưng với giả định tất cả mẫu unlabeled đều thuộc lớp mới. Giả định này vẫn quá chặt so với thực tế, bởi trong hầu hết các ứng dụng, tập dữ liệu không có nhãn chứa đồng thời cả mẫu thuộc lớp đã biết lẫn mẫu thuộc lớp mới.

Bài toán **Khám phá Danh mục Tổng quát** (Generalized Category Discovery — GCD), được đề xuất bởi Vaze và cộng sự [4], ra đời nhằm giải quyết đúng thách thức này: cho một tập nhỏ dữ liệu có nhãn $\mathcal{D}_l$ chỉ chứa C_{old} lớp đã biết, cùng một tập lớn dữ liệu

không có nhãn $\mathcal{D}_u$ chứa cả mẫu từ C_{old} lớp cũ lẫn C_{new} lớp mới, mô hình phải đồng thời *phân loại* các mẫu thuộc lớp cũ và *khám phá* các lớp mới — một bài toán khó hơn NCD rất nhiều vì ranh giới giữa đã biết và chưa biết nằm ngay trong cùng một tập dữ liệu.

Tuy nhiên, các phương pháp GCD tiên tiến hiện tại vẫn tồn tại những khoảng trống đáng kể. Cụ thể, luận văn này nhận diện ba hạn chế chính:

1. **Thiếu cơ chế phân tách Known/Unknown tường minh.** Các phương pháp end-to-end như SimGCD [5], μ GCD [6], và GPC [7] xử lý bài toán GCD thông qua học biểu diễn và phân cụm đồng thời, nhưng không tích hợp một bước phát hiện Out-of-Distribution (OOD) có cơ sở lý thuyết vào pipeline. Việc thiếu cơ chế phân tách này khiến mô hình dễ bị nhầm lẫn giữa mẫu Known (lớp cũ) và Unknown (lớp mới), đặc biệt khi hai nhóm có phân phối đặc trưng gần nhau.
2. **Sự phụ thuộc vào Oracle K.** CiPR [8] — phương pháp baseline chính của luận văn — đạt hiệu năng cao trên CIFAR-100 (All ACC = 81.5%, Table 6, Row 3) nhưng yêu cầu giá trị $K = 100$ (tổng số lớp) phải được cung cấp trước. Trong triển khai thực tế, số lượng lớp mới là ẩn số, khiến giả định Oracle K trở thành điểm yếu về tính ứng dụng.
3. **Softmax confidence không đáng tin cậy cho OOD.** Hendrycks và Gimpel [9] đã chỉ ra rằng giá trị xác suất tối đa từ softmax (Maximum Softmax Probability) thường bị *overconfident* đối với các mẫu OOD. Điều này có nghĩa rằng một mẫu thuộc lớp mới vẫn có thể nhận được xác suất softmax rất cao cho một lớp cũ nào đó, dẫn đến phân loại sai. GEN (Generalized ENTropy) [10] được đề xuất nhằm khắc phục chính vấn đề này bằng cách đo entropy tổng quát trên phân phối softmax, cung cấp một thước đo OOD đáng tin cậy hơn.

Xuất phát từ ba khoảng trống trên, luận văn này đề xuất phương pháp **GESNC** (GEN-Augmented Semi-Supervised Selective Neighbor Clustering), một pipeline kết

hợp: (i) trích xuất đặc trưng sâu bằng DINO ViT-B/16, (ii) hiệu chỉnh activation bằng React, (iii) cổng lọc GEN entropy để sinh pseudo-labels cho các mẫu tự tin nhất, và (iv) phân cụm semi-supervised SNC với dual-anchor constraints. Phương pháp được xây dựng trên nền tảng CiPR nhưng bổ sung các đóng góp mới nhằm cải thiện đáng kể hiệu năng phân loại, đặc biệt trên các lớp mới (Unknown classes).

1.2 Đóng góp của Luận văn

Luận văn này đề xuất phương pháp **GESNC**, bao gồm các đóng góp kỹ thuật chính như sau:

1. **Cổng Entropy Tổng quát (GEN Gate) tích hợp Pseudo-labeling.** Thay vì chỉ sử dụng GEN entropy như một bộ lọc OOD đơn thuần (loại bỏ mẫu bất thường), luận văn đề xuất sử dụng GEN một cách *chủ động*: top 10% mẫu có GEN score thấp nhất (tức là tự tin nhất vào lớp Known) được gán pseudo-labels dựa trên argmax softmax. Các pseudo-labels này sau đó được inject vào SNC dưới dạng anchor constraints, mở rộng pool thông tin giám sát từ khoảng 20.000 mẫu có nhãn thật lên 23.513 anchors trong cấu hình PCT=10. Đây là đóng góp chưa có trong CiPR gốc [8].
2. **Hiệu chỉnh Feature Activation bằng React Clipping.** Luận văn tích hợp kỹ thuật React [11] — truncate các activation units tại quantile $q = 0.99$ trên tập in-distribution — vào giai đoạn tiền xử lý trước GEN Gate nhằm giảm thiểu hiện tượng overconfidence của mạng nơ-ron, góp phần hình thành nên cấu hình tốt nhất của hệ thống.
3. **Pool Anchor Kép (Dual Anchor Pool) cho SNC semi-supervised.** Thuật toán SNC cốt lõi trong CiPR ban đầu là unsupervised. Phiên bản CiPR 2024 đã bổ sung quan hệ $u-\ell$ nhưng chưa có cơ chế pseudo-labeling tạo hard anchors. GESNC mở rộng thêm bằng cách inject đồng thời hai loại anchors: (i) ground-truth labeled anchors từ tập $\mathcal{D}_l$, và (ii) GEN pseudo-label anchors từ bước trước. Hai nhóm

anchors này tạo thành must-link và cannot-link constraints trong đồ thị 1-NN của SNC, hướng dẫn quá trình phân cụm theo thông tin ngữ nghĩa thay vì chỉ dựa vào khoảng cách hình học.

4. **Đánh giá thực nghiệm và phân tích trade-off trên CIFAR-100.** Với cấu hình single-run tốt nhất trong grid search mới ($M = 16$, $\gamma = 0.05$, PCT=10, React $q = 0.99$), GESNC đạt All ACC = 84.97%, Old ACC = 85.69%, New ACC = 83.53%, và H-score = 84.59% trên unlabeled train CIFAR-100. Tuy nhiên, kết quả multi-seed cho thấy cải thiện không đồng đều giữa Old ACC và New ACC. Vì vậy, luận văn diễn giải GESNC như một mở rộng OOD-aware của CiPR nhằm phân tích trade-off Known–Unknown, thay vì khẳng định cải thiện tuyệt đối trên mọi chỉ số. Kết quả chi tiết được trình bày tại Chương 4.

1.3 Phạm vi và Giới hạn

Để đảm bảo tính trung thực học thuật, luận văn thừa nhận các giới hạn sau của phương pháp đề xuất:

- **Giả định Oracle K.** Giống như CiPR gốc và hầu hết các phương pháp GCD hiện tại, GESNC yêu cầu biết trước tổng số lớp $K = C_{\text{old}} + C_{\text{new}}$. Với CIFAR-100, $K = 100$ được cung cấp sẵn. Trong triển khai thực tế, giá trị này cần được ước lượng bằng các phương pháp bổ sung (ví dụ: silhouette analysis hoặc elbow method), và sai số trong ước lượng K có thể ảnh hưởng đáng kể đến chất lượng phân cụm.
- **Phạm vi thực nghiệm.** Kết quả chính được báo cáo trên CIFAR-100 với giao thức transductive (train + test gộp). Thực nghiệm trên CUB-200-2011 cho thấy cải thiện hạn chế hơn (All ACC $\approx 59\%$), phản ánh thách thức của fine-grained recognition và sự khác biệt về chất lượng pretrained features giữa hai dataset. Luận văn chưa kiểm nghiệm trên các bộ dữ liệu lớn hơn như ImageNet-100 hay Herbarium-19.

- **Chi phí tính toán.** Bước `req_numclust()` trong SNC tính pairwise distance trên toàn bộ anchor pool, có độ phức tạp $\mathcal{O}(n_a^2)$ với $n_a \approx 23.500$ anchors. Trên CIFAR-100, bước này tiêu tốn khoảng 2.2 GB RAM và vẫn trong giới hạn chấp nhận được. Tuy nhiên, khi mở rộng sang dataset lớn hơn (ImageNet-100 với $\sim 130k$ mẫu), n_a có thể vượt 50.000, gây nguy cơ OOM (Out-of-Memory).

Những giới hạn trên được thảo luận chi tiết trong Chương 5 cùng với các hướng phát triển tương lai.

1.4 Cấu trúc Luận văn

Luận văn được tổ chức thành 5 chương với cấu trúc như sau:

Chương 1 — Giới thiệu (chương hiện tại) trình bày bối cảnh nghiên cứu, các khoảng trống trong lĩnh vực GCD, đóng góp của luận văn, và phạm vi giới hạn.

Chương 2 — Tổng quan Nghiên cứu Liên quan khảo sát các công trình nền tảng: kiến trúc Vision Transformer và DINO, bài toán GCD và các biến thể, kỹ thuật OOD detection (GEN, React), phân cụm SNC, và phương pháp CiPR — baseline chính của luận văn.

Chương 3 — Phương pháp Đề xuất mô tả chi tiết kiến trúc toán học của pipeline GESNC: trích xuất đặc trưng bằng DINO, hiệu chỉnh React, cổng GEN Gate với pseudo-labeling, và phân cụm semi-supervised SNC.

Chương 4 — Thực nghiệm và Kết quả trình bày thiết lập thực nghiệm, baseline reproduction của CiPR, và các ablation study phân tích vai trò của từng thành phần pipeline.

Chương 5 — Kết luận tóm tắt các kết quả chính, thảo luận ý nghĩa khoa học, và

đề xuất hướng nghiên cứu mở rộng.

CHƯƠNG 2

Tổng quan Nghiên cứu Liên quan

2.1 Self-supervised learning và Vision Transformer DINO

Trong những năm gần đây, học máy đã chuyển dịch mạnh mẽ từ việc phụ thuộc vào dữ liệu có nhãn sang khai thác tiềm năng khổng lồ của dữ liệu không nhãn thông qua self-supervised learning. Đối với bài toán Generalized Category Discovery, việc sở hữu một bộ trích xuất đặc trưng có khả năng tổng quát hóa cao là yếu tố then chốt. Thay vì huấn luyện từ đầu vốn đòi hỏi lượng dữ liệu khổng lồ và dễ dẫn đến hiện tượng overfitting với các lớp đã biết, việc sử dụng các đặc trưng tiền huấn luyện từ SSL cho phép mô hình nắm bắt được cấu trúc ngữ nghĩa của dữ liệu một cách khách quan, giúp phân biệt hiệu quả cả các đối tượng thuộc lớp đã biết và lớp chưa biết.

2.1.1 Học tương phản và các kỹ thuật SSL tiêu biểu

Cốt lõi của SSL trong thị giác máy tính hiện đại chủ yếu dựa trên nguyên lý học tương phản. Mục tiêu của phương pháp này là học một không gian biểu diễn sao cho các biến thể khác nhau của cùng một hình ảnh (positive pairs) được kéo lại gần nhau, trong khi các hình ảnh khác nhau (negative pairs) bị đẩy ra xa.

SimCLR: Nền tảng của học tương phản

SimCLR [12] đã thiết lập một khung làm việc đơn giản nhưng rất hiệu quả dựa trên hàm mất mát Normalized Temperature-scaled Cross Entropy (NT-Xent). Giả sử một lô dữ liệu có N hình ảnh, thông qua chiến lược tăng cường dữ liệu, mỗi ảnh được biến đổi thành hai phiên bản khác nhau, tạo ra $2N$ mẫu. Với một cặp dương (i, j) , hàm mất mát được định nghĩa như sau:

$$\mathcal{L}_{i,j} = -\log \frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)} \quad (2.1)$$

Trong đó, sim thường là độ tương đồng Cosine, và τ là tham số nhiệt độ nhằm điều chỉnh độ tập trung của phân phối. Điểm mấu chốt của SimCLR nằm ở chiến lược tăng cường dữ liệu mạnh mẽ. Tác giả đã chứng minh rằng việc kết hợp các phép biến đổi như cắt ngẫu nhiên, làm mờ Gaussian và đặc biệt là biến đổi màu sắc đóng vai trò quyết định trong việc ngăn chặn mô hình học các đặc trưng không quan trọng, ép mô hình phải hiểu nội dung ngữ nghĩa bên trong ảnh.

MoCo và cơ chế Momentum Encoder

Trái ngược với SimCLR đòi hỏi kích thước lô (batch size) rất lớn để có nhiều mẫu âm, MoCo [13] giải quyết vấn đề bằng cách sử dụng một **Memory Bank** (ngân hàng bộ nhớ) dưới dạng hàng đợi để lưu trữ các đặc trưng từ các lô trước đó. Để giữ cho các đặc trưng trong hàng đợi luôn nhất quán, MoCo sử dụng cơ chế *Momentum Encoder*: chỉ có mạng chính (query encoder) được cập nhật bằng lan truyền ngược, mạng còn lại (key encoder) cập nhật theo trung bình động:

$$\theta_k \leftarrow m\theta_k + (1 - m)\theta_q \quad (2.2)$$

Với m là hệ số momentum (thường rất lớn, khoảng 0.999). Điều này giúp tạo ra một không gian biểu diễn ổn định và tiết kiệm tài nguyên tính toán.

Sự phát triển của các phương pháp Non-contrastive

Tiếp nối SimCLR và MoCo, các phương pháp như BYOL [14] và DINO [15] đã chứng minh rằng mô hình có thể học biểu diễn tốt mà không cần đến các mẫu âm, từ đó tránh được các vấn đề về representation collapse thông qua các kỹ thuật như dự đoán trực tiếp hoặc chuẩn hóa đầu ra.

2.1.2 Kiến trúc Vision Transformer (ViT)

Song song với sự phát triển của SSL, kiến trúc Vision Transformer [16] đã thay thế dần CNN để trở thành lựa chọn hàng đầu cho các tác vụ trích xuất đặc trưng nhờ khả năng mô hình hóa các mối quan hệ toàn cục.

Cơ chế hoạt động của ViT

ViT chia hình ảnh đầu vào thành các patches có kích thước cố định (ví dụ 16×16). Các mảnh này được trải phẳng và chiếu vào một không gian nhúng. Vì cơ chế Self-Attention không có tính chất thứ tự, một vector positional encoding được cộng thêm vào để mô hình nhận biết được cấu trúc không gian của ảnh.

Phần quan trọng nhất của ViT là cơ chế Multi-head Self-Attention (MSA). Với các ma trận truy vấn (Query - Q), chìa khóa (Key - K) và giá trị (Value - V), sự tương quan giữa các phần tử được tính toán bằng công thức:

$$\text{Attn}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V \quad (2.3)$$

Ở đây, $\sqrt{d_k}$ là đại lượng chuẩn hóa để tránh hiện tượng gradient bị triệt tiêu khi giá trị tích vô hướng quá lớn.

Vai trò của CLS token

Tương tự như trong xử lý ngôn ngữ tự nhiên, ViT đưa thêm một token đặc biệt gọi là **[CLS] token** vào đầu chuỗi đầu vào. Token này tương tác với tất cả các patch khác thông qua các lớp Self-Attention. Sau khi đi qua toàn bộ các tầng Transformer, CLS token đóng vai trò là vector tổng hợp thông tin của toàn bộ hình ảnh. Trong các bài toán hạ nguồn như GCD, giá trị của CLS token chính là đặc trưng được sử dụng để tiến hành gom cụm và phân loại.

2.1.3 DINO

DINO (Distillation with no labels) [15] là sự kết hợp hiệu quả giữa kiến trúc ViT và self-supervised learning theo knowledge distillation.

Cơ chế Self-distillation

DINO sử dụng cấu trúc gồm hai mạng có cùng kiến trúc: Teacher và Student. Mạng Student được huấn luyện để dự đoán đầu ra của mạng Teacher. Điểm đặc biệt là mạng Teacher được cập nhật thông qua cơ chế Momentum từ Student, tương tự như MoCo, nhưng áp dụng trực tiếp trên các xác suất đầu ra sau khi đã qua hàm Softmax với kỹ thuật centering và sharpening để tránh sụp đổ biểu diễn.

Tại sao DINO đặc biệt hiệu quả cho GCD?

DINO sở hữu những đặc điểm vượt trội khiến nó trở thành backbone tiêu chuẩn cho bài toán GCD:

- **Emergent Semantic Segmentation:** Các nghiên cứu đã chỉ ra rằng các lớp Attention của DINO tự động hội tụ vào các thực thể chính trong ảnh mà không cần bất kỳ nhãn giám sát nào.

- **Sự tách biệt của CLS token:** CLS token trong DINO được tối ưu hóa để nắm bắt các thông tin phân loại rất mạnh mẽ. Trong bài báo gốc về GCD, Vaze et al. [4] đã thực hiện benchmark thực nghiệm và chứng minh rằng ViT-B/16 được huấn luyện bằng DINO cho kết quả vượt xa SimCLR hay các phương pháp SSL khác trên các tập dữ liệu như CIFAR-100 và ImageNet.
- **Khả năng gom cụm:** Không gian đặc trưng của DINO có tính chất neighborhood rất tốt, nghĩa là các hình ảnh cùng một lớp (dù chưa biết nhãn) sẽ nằm rất gần nhau trong không gian đặc trưng 768 chiều.

Trong phương pháp được đề xuất trong luận văn này (GESNC), chúng tôi lựa chọn backbone **ViT-B/16 DINO** và giữ nguyên trạng thái đóng băng hoàn toàn (frozen). Điều này nhằm tận dụng tối đa khả năng biểu diễn tổng quát của DINO mà không làm mất đi các cấu trúc ngữ nghĩa quý giá đã học được trong quá trình tiền huấn luyện. CLS token 768 chiều sẽ được trích xuất trực tiếp làm đầu vào cho các bước gom cụm và suy diễn tiếp theo.

2.2 Phát hiện ngoài phân phối (OOD Detection)

Trong các hệ thống cũ, hệ thống thường được giả định trong môi trường thế giới đóng, vì vậy khi đối mặt với môi trường thế giới mở trong các bài toán thực tế có số lượng tập dữ liệu lớn hệ thống hay dự đoán sai lệch rơi vào lỗi quá tự tin. Đây là phần trình bày các bước phát triển của kỹ thuật phát hiện dữ liệu ngoài phân phối và kỹ thuật Generalized Entropy để giúp phát hiện ngoài phân phối tốt hơn trên các tập dữ liệu lớn.

2.2.1 Softmax và Maximum Softmax Probability

Softmax [9] hay được gọi là hàm mũ chuẩn hóa (normalized exponential)[17] nhưng trong trường hợp sử dụng trong các kiến trúc mạng nơ-ron (neural networks) Softmax

được mô tả là hàm dùng để tính toán các xác suất dự đoán (prediction probabilities)[9] mặc dù xác suất Softmax cung cấp có độ tin cậy kém nhưng thông kê các xác suất này lại hữu ích để phân biệt một mẫu dữ liệu có bị phân loại sai hoặc thuộc về một phân phối khác so với dữ liệu huấn luyện hay không. Theo tài liệu [9], công thức Softmax được định nghĩa là:

$$P(y = i|\mathbf{x}) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (2.4)$$

MSP [9] chính là xác suất lớn nhất từ đầu ra của hàm softmax và sử dụng giá trị này làm điểm số để phân loại. Theo tài liệu [9], công thức MSP được định nghĩa là:

$$MSP = \max_c p_c \quad (2.5)$$

Hạn chế: Các nghiên cứu đã chỉ ra rằng mạng neural thường bị hiện tượng overconfident. Ngay cả với các đầu vào OOD không liên quan, mô hình vẫn có thể gán cho chúng một mức xác suất cực đại rất cao, đặc biệt khi mô hình đã được huấn luyện kỹ. Điều này khiến khoảng cách về điểm số giữa dữ liệu đã biết và chưa biết trở nên mong manh, dẫn đến sai số lớn trong phát hiện.

2.2.2 Cải tiến Energy-based Score

Phương pháp phát hiện dữ liệu ngoài phân phối dựa trên năng lượng [18] đề xuất sử dụng trực tiếp giá trị năng lượng tự do làm tiêu chí phân loại. Thay vì dựa vào xác suất hậu nghiệm đã chuẩn hóa, Energy score cho một đầu vào x được tính toán như sau:

$$E(x; f) = -T \log \sum_{k=1}^K \exp(f_k(x)/T) \quad (2.6)$$

Việc sử dụng giá trị năng lượng này mang lại sự cải thiện đáng kể so với phương

pháp MSP truyền thống nhờ vào bản chất toán học của hàm năng lượng. Điểm mấu chốt nằm ở việc Energy score không bị chuẩn hóa, giúp nó phản ánh mật độ xác suất chưa chuẩn hóa của dữ liệu tốt hơn so với hàm Softmax.

Trong cơ chế của Softmax, phép toán chuẩn hóa $\sum e^{f_i/T}$ ở mẫu số vô tình triệt tiêu thông tin về cường độ tuyệt đối của các logits, chỉ giữ lại mối tương quan tương đối giữa các lớp. Điều này dẫn đến hiện tượng overconfidence, khi một mẫu OOD có các logits đều thấp vẫn có thể nhận được giá trị xác suất lớn nếu một logit chiếm ưu thế nhẹ. Ngược lại, Energy score giữ nguyên giá trị tổng hợp từ các logits, giúp bảo toàn thông tin về sự hiện diện của dữ liệu trong không gian đặc trưng.

Xét về mặt lý thuyết, giá trị $-E(x; f)$ tỉ lệ thuận với logarit của mật độ xác suất biên $p(x)$. Do đó, dữ liệu ID thuộc vùng mật độ cao sẽ có mức năng lượng thấp, trong khi dữ liệu OOD thuộc vùng mật độ thấp sẽ có mức năng lượng cao rõ rệt. Chính vì không bị bó buộc trong phạm vi $[0, 1]$ như xác suất, Energy score tạo ra một khoảng cách phân tách lớn hơn và ổn định hơn giữa ID và OOD giúp nhận diện các mẫu dữ liệu lạ hiệu quả hơn.

2.2.3 Generalized Entropy

Phương pháp Generalized Entropy (GEN) [10] được thiết kế nhằm khai thác tối đa thông tin từ phân phối xác suất dự đoán mà không cần quyền truy cập vào dữ liệu huấn luyện hay các thông số nội tại của mô hình.

Công thức toán học:

Giả sử $\hat{p}_{(1)} \geq \hat{p}_{(2)} \geq \dots \geq \hat{p}_{(K)}$ là các xác suất sau Softmax được sắp xếp giảm dần. Điểm số GEN được tính bằng công thức:

$$\text{GEN}(x; M, \gamma) = \sum_{m=1}^M \hat{p}_{(m)}^\gamma \cdot (1 - \hat{p}_{(m)})^\gamma \quad (2.7)$$


Trong đó:

- M : Tham số cắt (truncation), chỉ xét Top- M lớp (ví dụ $M = 8$ trong thực nghiệm).
- $\gamma > 0$: Hệ số độ sắc nét (sharpness coefficient), điều chỉnh độ nhạy của hàm số.

Hàm thành phần $g(p) = p^\gamma(1 - p)^\gamma$ đạt giá trị nhỏ khi p tiến về 0 hoặc 1.

- **Mẫu Known:** Phân phối xác suất thường ”nhọn”(sharp), xác suất tập trung vào một lớp chủ đạo ($\hat{p}_{(1)} \approx 1$) và các lớp khác rất nhỏ (≈ 0). Khi đó, các hạng tử trong tổng GEN đều nhỏ, dẫn đến **GEN score thấp**.
- **Mẫu Unknown:** Phân phối xác suất ”phẳng”(flat), các lớp có xác suất tương đương nhau và nằm ở mức trung bình. Khi đó, các hạng tử $p^\gamma(1 - p)^\gamma$ đạt giá trị lớn, dẫn đến **GEN score cao**.

GEN vượt trội hơn MSP và Energy score trên hầu hết các benchmark lớn như ImageNet-1k. Việc sử dụng tham số M giúp loại bỏ nhiều từ các tail classes vốn chứa nhiều sai số không đáng kể, làm cho điểm số ổn định hơn trong các bài toán có số lượng lớp lớn.



Hình 2.1: Phân cấp các bài toán phát hiện dữ liệu ngoài phân phối. GCD nằm trong nhánh Multi-Class Novelty Detection kết hợp với khả năng nhận diện lớp cũ.

2.2.4 Adaptive Thresholding

Trong hệ thống GESNC, chúng tôi không sử dụng một ngưỡng GEN cố định vì phân phối điểm số thay đổi theo từng tập dữ liệu và giai đoạn huấn luyện. Thay vào đó, một ngưỡng thích nghi dựa trên phân vị (percentile) được áp dụng:

$$\tau = \text{Percentile}_{10}(\{\text{GEN}(x_i)\}_{i=1}^N) \quad (2.8)$$

Cơ chế này đảm bảo mô hình luôn lọc ra 10% số mẫu có độ tự tin cao nhất để thực hiện gán nhãn giả, giúp duy trì sự ổn định của quá trình clustering.

2.2.5 Nhận xét

Việc tích hợp GEN vào pipeline GCD không chỉ đơn thuần là để loại bỏ OOD, mà còn đóng vai trò là bộ lọc chất lượng cho quá trình sinh nhãn giả. Đây là cầu nối quan trọng để chuyển đổi sang semi-supervised learning với độ tin cậy cao hơn.

2.3 Khám phá Danh mục Tổng quát (Generalized Category Discovery - GCD)

2.3.1 Định nghĩa hình thức bài toán GCD

Khám phá Danh mục Tổng quát (Generalized Category Discovery - GCD) đại diện cho một bước tiến quan trọng hướng tới việc xây dựng các hệ thống trí tuệ nhân tạo có khả năng tự thích ứng trong môi trường thế giới mở [4]. Khác với các mô hình truyền thống hoạt động dựa trên giả định thế giới đóng, GCD đặt ra một thách thức sát với thực tế hơn: hệ thống phải vừa duy trì khả năng nhận diện các đối tượng cũ, vừa phải có khả năng phân loại các đối tượng mới lạ thành các cụm mang tính ngữ nghĩa.

Về mặt hình thức, bài toán GCD được định nghĩa dựa trên thiết lập ký hiệu chuẩn từ Vaze et al. [4]:

- **Tập dữ liệu có nhãn:** $\mathcal{D}_l = \{(x_i, y_i)\}$ với $y_i \in \mathcal{C}^{\text{old}}$, đại diện cho tập các lớp đã biết mà mô hình đã được tiếp cận trong quá trình huấn luyện supervised learning.
- **Tập dữ liệu không nhãn:** $\mathcal{D}_u = \{x_j\}$ với nhãn ẩn $y_j \in \mathcal{C}^{\text{old}} \cup \mathcal{C}^{\text{new}}$. Đây là tập hợp hỗn hợp, nơi các mẫu có thể thuộc về các lớp cũ hoặc các danh mục mới.
- **Mục tiêu:** Thực hiện gán nhãn cụm cho tất cả các mẫu trong tập $\mathcal{D}_u$, đồng thời phân tách chính xác giữa các thực thể thuộc lớp cũ và lớp mới.

- **Điều kiện ràng buộc:** Tập lớp cũ và lớp mới hoàn toàn tách biệt ($\mathcal{C}^{\text{old}} \cap \mathcal{C}^{\text{new}} = \emptyset$).

Trong kịch bản này, số lượng lớp cũ $|\mathcal{C}^{\text{old}}|$ được coi là đã biết, trong khi số lượng lớp mới $|\mathcal{C}^{\text{new}}|$ là một ẩn số cần được ước tính.

Độ chính xác phân cụm (Clustering Accuracy - ACC) được tính toán thông qua việc tìm ánh xạ tối ưu giữa các cụm dự đoán và nhãn thực tế bằng thuật toán Hungarian [4]:

$$ACC = \max_{p \in \mathcal{P}(\mathcal{C}^{\text{all}})} \frac{1}{M} \sum_{j=1}^M \mathbb{1}_{\{y_j = p(\hat{y}_j)\}} \quad (2.9)$$

2.3.2 Tiến trình phát triển từ NCD đến GCD

Bản chất của GCD là sự hợp nhất và nối lỏng các giả định gò bó của các bài toán nhận dạng trước đây nhằm phản ánh đúng thực tế khi hệ thống hiếm khi biết chắc chắn liệu dữ liệu mới có thuộc về nhóm đã học hay không.

- **Novel Category Discovery (NCD):** Framework được chuẩn hóa bởi Han et al. [3]. Tuy nhiên, phương pháp này dựa trên giả định khắt khe rằng tập không nhãn $\mathcal{D}_u$ chỉ chứa các lớp mới hoàn toàn, điều này làm hạn chế khả năng ứng dụng thực tế khi dữ liệu thu thập thêm thường xuyên chứa các đối tượng thuộc danh mục cũ.
- **OpenMix:** Công trình của Zhu et al. là nghiên cứu tiên phong bắt đầu nối lỏng giả định của NCD bằng cách thừa nhận sự tồn tại đồng thời của cả lớp cũ và lớp mới trong tập dữ liệu không nhãn, đặt nền móng cho việc quản lý ranh giới lớp phức tạp.
- **Framework GCD:** Vaze et al. [4] đã chính thức định nghĩa khung bài toán tổng quát. Họ chứng minh rằng các phương pháp học tham số truyền thống dễ bị thiên kiến vào lớp cũ và đề xuất hướng tiếp cận dựa trên phân cụm không tham số để đạt được sự cân bằng.

2.3.3 Cơ chế học biểu diễn tương phản trong GCD

Để giải quyết sự phức tạp của việc phân tách các cụm trong không gian đặc trưng, các phương pháp hiện đại tập trung vào việc Representation Learning thông qua Hybrid Contrastive Learning.

Mô hình thường sử dụng mạng ViT được tiền huấn luyện bằng phương pháp self-supervised DINO. Quá trình tinh chỉnh được thực hiện bằng cách kết hợp:

1. **Học đối chiếu unsupervised:** Áp dụng cho toàn bộ dữ liệu để học các đặc trưng hình ảnh mạnh mẽ, không phụ thuộc vào nhãn.
2. **Học đối chiếu supervised:** Sử dụng các nhãn từ $\mathcal{D}_l$ để ép các mẫu cùng lớp cũ lại gần nhau, tạo ra các vùng mật độ cao trong không gian đặc trưng nhằm dẫn dắt quá trình phân cụm cho dữ liệu không nhãn.

2.3.4 Các phương pháp GCD nổi bật và Bảng so sánh

Sự phát triển của GCD tập trung vào việc tối ưu hóa không gian đặc trưng và các thuật toán phân cụm semi-supervised learning hiệu quả.

- **GCD [4]:** Sử dụng đặc trưng ViT-DINO kết hợp với thuật toán Semi-supervised k-means, nơi các trọng tâm lớp cũ được khởi tạo từ dữ liệu có nhãn.
- **SimGCD [5]:** Cải tiến bằng cách sử dụng đầu phân loại tham số kết hợp với cơ chế self-distillation nhằm tăng cường độ ổn định của các đại diện lớp.
- **μ GCD [6]:** Đề xuất sử dụng thuật toán phân cụm Mean-shift, cho phép mô hình linh hoạt hơn trong việc xác định hình dạng các cụm đặc trưng mà không phụ thuộc vào việc khởi tạo trọng tâm cố định.

- **GPC [7]:** Sử dụng mô hình sinh để mô hình hóa các Prototype của lớp, giúp phân tách không gian đặc trưng tốt hơn thông qua việc lấy mẫu tiềm năng.
- **CiPR [8]:** Đây là baseline chính của nghiên cứu này, tập trung vào việc học các mối quan hệ xuyên thực thể và cơ chế SNC để tối ưu ranh giới lớp.

Bảng 2.1: So sánh các phương pháp GCD tiêu biểu trên tập dữ liệu CIFAR-100

Phương pháp	Kỹ thuật cốt lõi	All (%)	Old (%)	New (%)
GCD [4]	Semi-supervised k-means	70.8	77.6	57.0
SimGCD [5]	Parametric + self-distillation	80.1	81.2	77.8
CiPR [8]	SNC + cross-instance relations	81.5	82.4	79.7
GESNC (Ours)	GEN Gate + Semi-SNC	84.97	85.69	83.53

Các kết quả GCD, SimGCD và CiPR được trích từ [8]; dòng GESNC sử dụng kết quả single-run tốt nhất của luận văn trên CIFAR-100.

2.4 Framework CiPR và Thuật toán Selective Neighbor Clustering (SNC)

Trong các phương pháp tiếp cận bài toán Generalized Category Discovery, Framework CiPR [8] là một giải pháp hiệu quả. Thay vì chỉ tập trung vào việc học biểu diễn từ dữ liệu có nhãn, CiPR khai thác mối quan hệ chéo giữa toàn bộ các thực thể trong tập dữ liệu. Mục này sẽ trình bày chi tiết về cơ chế thiết lập Cross-instance Positive Relations và quy trình phân cụm phân cấp SNC.

2.4.1 Cross-instance Positive Relations

Các phương pháp self-supervised learning truyền thống như SimCLR thường chỉ coi các biến thể tăng cường của cùng một hình ảnh là cặp instance-level positives. CiPR mở rộng khái niệm này lên instance-level xuyên suốt toàn bộ tập dữ liệu.

Khái niệm Cross-instance Positives

Cross-instance Positives được định nghĩa là mối quan hệ giữa hai mẫu dữ liệu khác nhau x_i và x_j nhưng có khả năng cao thuộc cùng một phạm trù ngữ nghĩa. Trong bối cảnh GCD, việc xác định các cặp này rất quan trọng vì:

- Nó cho phép mô hình học được các đặc trưng chung của lớp từ tập dữ liệu chưa có nhãn.
- Nó tạo ra sự nhất quán về biểu diễn giữa tập D_L (có nhãn) và tập D_U (chưa nhãn).

Cơ chế Contrastive Learning dựa trên quan hệ chéo

CiPR tích hợp các quan hệ này vào hàm mất mát InfoNCE mở rộng. Cho một batch dữ liệu, tập các cặp tích cực cho mẫu i không còn là một cặp đơn lẻ mà là một tập hợp $\mathcal{P}(i)$ bao gồm các láng giềng gần nhất được xác định bởi thuật toán SNC. Hàm mất mát được định nghĩa như sau:

$$\mathcal{L}_{CiPR} = -\frac{1}{|\mathcal{P}(i)|} \sum_{j \in \mathcal{P}(i)} \log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} \quad (2.10)$$

Việc tối ưu hóa hàm mất mát này giúp thu hẹp khoảng cách giữa các thực thể thuộc cùng một cụm trong không gian nhúng, từ đó tạo ra các ranh giới phân loại sắc nét hơn.

2.4.2 Thuật toán Selective Neighbor Clustering (SNC)

SNC là trái tim của framework CiPR, được xây dựng dựa trên thuật toán FINCH nhằm mục đích phân cụm dữ liệu quy mô lớn một cách hiệu quả và tự động.

Điểm khởi đầu của SNC là xây dựng một đồ thị láng giềng gần nhất (1-NN). Với mỗi điểm dữ liệu i , ta tìm láng giềng gần nhất của nó là j . Ma trận kề A được xác định bởi:

$$A_{i,j} = 1 \quad \text{nếu} \quad j = \operatorname{argmin}_{k \neq i} \|z_i - z_k\|^2 \quad (2.11)$$

Tuy nhiên, đồ thị 1-NN thường bị rời rạc thành quá nhiều cụm nhỏ. Để giải quyết vấn đề này, SNC áp dụng phép toán second-order connectivity thông qua ma trận $\bar{A}$:

$$\bar{A} = (A + I)(A + I)^T \quad (2.12)$$

Trong đó I là ma trận đơn vị. Về mặt logic, hai điểm i và j sẽ được nối với nhau nếu chúng có chung một láng giềng gần nhất hoặc điểm này là láng giềng của điểm kia. Cơ chế này cho phép thuật toán "lan truyền" quan hệ đương một cách tự nhiên mà không cần thiết lập ngưỡng khoảng cách cứng nhắc.

SNC hoạt động theo cơ chế phân cấp. Quy trình chi tiết bao gồm các bước sau:

1. **Khởi tạo:** Xác định các thành phần liên thông từ ma trận $\bar{A}$. Mỗi thành phần liên thông tạo thành một cụm ban đầu, hình thành phân hoạch cấp thấp nhất P_0 .
2. **Đại diện cụm:** Với mỗi cụm trong P_0 , tính toán vector đặc trưng trung bình (centroid).
3. **Lặp lại phân cấp:** Coi các centroids này là các điểm dữ liệu mới và lặp lại bước xây dựng đồ thị láng giềng. Quá trình này tạo ra các phân hoạch cao hơn $P_1, P_2, \dots, P_L$ với số lượng cụm giảm dần theo hàm mũ.

4. **Điều chỉnh số cụm:** Trong GCD, số lượng lớp K thường được giả định là đã biết. SNC sử dụng hàm `req_numclust()` để tìm phân hoạch gần nhất có số cụm $K' \geq K$, sau đó thực hiện gộp các cụm có khoảng cách centroids gần nhất cho đến khi đạt đúng giá trị K .

2.4.3 Phân tích hiệu năng và so sánh thực nghiệm

Theo các báo cáo trong bài báo CiPR, phương pháp này đạt được hiệu suất vượt trội trên các tập dữ liệu chuẩn như CUB-200, Stanford Cars và đặc biệt là Herbarium19.

Bảng 2.2: So sánh hiệu năng giữa CiPR [8] và GCD [4] trên các tập dữ liệu (All ACC, %)

Phương pháp	CIFAR-100	CUB-200	Stanford Cars	Herbarium19
GCD [4]	70.8	51.3	39.0	35.4
CiPR [8]	81.5	57.1	47.0	36.8
<i>Cải thiện</i>	<i>+10.7</i>	<i>+5.8</i>	<i>+8.0</i>	<i>+1.4</i>

Sự cải thiện này đến từ việc không gian biểu diễn của CiPR phân tách các danh mục tốt hơn, giảm thiểu hiện tượng nhầm lẫn giữa các lớp đã biết và các lớp chưa biết trong tập dữ liệu không nhãn.

2.4.4 Giới hạn của CiPR và động lực phát triển GESNC

Mặc dù CiPR là một bước tiến lớn, nghiên cứu này đã chỉ ra ba điểm nghẽn quan trọng:

1. **Hạn chế của semi-supervised learning trong SNC:** Thuật toán SNC cốt lõi trong CiPR ban đầu được thiết kế hoàn toàn unsupervised learning. Mặc dù ở phiên bản 2024, CiPR đã bổ sung thêm các quan hệ giữa dữ liệu chưa nhãn và có nhãn ($u-\ell$),

nhưng hệ thống vẫn thiếu một cơ chế pseudo-labeling để tạo ra các hard anchors trực tiếp cho quá trình phân cụm.

2. **Sự phụ thuộc vào tham số K :** CiPR đòi hỏi số lượng cụm K phải chính xác. Trong thực tế open-world, việc xác định K cho dữ liệu chưa nhãn là một thách thức lớn.
3. **Vấn đề nhiễu OOD:** CiPR thực hiện phân cụm trên toàn bộ dữ liệu chưa nhãn mà không có bước sàng lọc các mẫu quá lạ hoặc các mẫu có độ tự tin thấp, dẫn đến việc nhiễu từ lớp mới có thể làm sai lệch cấu trúc của các lớp cũ.

Kết luận chuyển tiếp: Để khắc phục những hạn chế này, hệ thống GESNC được đề xuất trong luận văn sẽ cải tiến SNC theo hướng semi-supervised bằng cách sử dụng các nhãn giả từ GEN làm điểm neo, đồng thời tích hợp bộ lọc GEN gate để loại bỏ nhiễu trước khi tiến hành phân cụm.

2.5 Semi-supervised learning và Pseudo-labeling

Trong bối cảnh của Generalized Category Discovery, dữ liệu không chỉ đơn thuần là các mẫu không nhãn mà còn chứa đựng một phần dữ liệu đã được định danh. Việc tận dụng tri thức từ tập dữ liệu có nhãn để dẫn dắt quá trình khám phá các danh mục mới là cốt lõi của học bán Semi-supervised Learning. Chương này tập trung thảo luận về các cơ chế gom cụm dựa trên ràng buộc và các chiến lược giả nhãn (pseudo-labeling) hiện đại, từ đó làm nền tảng cho phương pháp đề xuất của luận văn.

2.5.1 Gom cụm semi-supervised dựa trên ràng buộc

Gom cụm semi-supervised truyền thống thường khai thác tri thức tiên nghiệm dưới dạng các ràng buộc cặp (pairwise constraints). Đây là cách tiếp cận tự nhiên nhất khi ta có một phần dữ liệu đã biết nhãn, cho phép định hình lại cấu trúc của không gian đặc trưng.

Hệ thống ràng buộc Must-link và Cannot-link

Khái niệm về các ràng buộc cặp lần đầu tiên được phổ biến rộng rãi bởi Basu et al. [19]. Thay vì chỉ dựa vào độ đo khoảng cách hình học đơn thuần, thuật toán sẽ tuân thủ hai quy tắc logic:

- **Must-link (ML):** Ký hiệu $\mathcal{M} = \{(\mathbf{x}_i, \mathbf{x}_j)\}$, ràng buộc này chỉ định rằng hai mẫu dữ liệu $\mathbf{x}_i$ và $\mathbf{x}_j$ bắt buộc phải được gán vào cùng một cụm. Trong GCD, các mẫu có cùng nhãn lớp hiển nhiên tạo thành các tập ML.
- **Cannot-link (CL):** Ký hiệu $\mathcal{C} = \{(\mathbf{x}_i, \mathbf{x}_j)\}$, ràng buộc này chỉ định rằng hai mẫu dữ liệu không được phép nằm trong cùng một phân vùng. Các mẫu thuộc hai lớp khác nhau trong tập dữ liệu có nhãn sẽ tạo thành các tập CL.

Việc tích hợp các ràng buộc này giúp thuật toán vượt qua các rào cản về mật độ dữ liệu không đồng nhất, ép buộc mô hình phải duy trì sự phân tách giữa các lớp cũ ngay cả khi chúng có đặc trưng tương đồng cao với một lớp mới nào đó.

Constrained k-means: Từ lý thuyết đến thực tiễn

Thuật toán Constrained k-means [20] là một bước tiến quan trọng từ k-means cổ điển. Hàm mục tiêu của nó không chỉ tối thiểu hóa tổng bình phương khoảng cách tới các tâm cụm mà còn phải thỏa mãn tập hợp các ràng buộc $\mathcal{M}$ và $\mathcal{C}$. Quá trình gán nhãn cho điểm $\mathbf{x}_i$ vào cụm k sẽ bị từ chối nếu nó dẫn đến việc vi phạm một ràng buộc ML với một điểm đã gán vào cụm k' ($k' \neq k$), hoặc vi phạm ràng buộc CL với một điểm trong cụm k .

Tuy nhiên, Constrained k-means gặp phải vấn đề về độ phức tạp tính toán và tính ”cứng nhắc”(hard constraints). Trong các bài toán thị giác máy tính với số lượng mẫu lớn, việc duy trì một ma trận ràng buộc khổng lồ là bất khả thi, đòi hỏi các phương pháp tiếp cận linh hoạt hơn thông qua đồ thị hoặc điểm neo.

SNC và cơ chế Anchor-based Must-link

Trong khuôn khổ luận văn này, cụ thể là tại thành phần xử lý `clustering.py`, chúng tôi kế thừa tư tưởng ràng buộc nhưng hiện thực hóa thông qua cơ chế **Anchor-based Must-link**. Thay vì thiết lập ràng buộc giữa mọi cặp điểm, chúng tôi xác định các *Anchors* là các mẫu dữ liệu có nhãn tiêu biểu nhất cho mỗi lớp. Thuật toán Selective Neighbor Clustering (SNC) sẽ thực hiện gán các mẫu không nhãn vào các cụm dựa trên sự tương đồng với các anchor này. Nếu một mẫu không nhãn nằm trong vùng lân cận cực gần của một anchor, một ràng buộc ML mềm (soft must-link) được thiết lập, giúp lan truyền tri thức từ lớp đã biết sang lớp chưa biết một cách ổn định.

2.5.2 Chiến lược Giả nhãn (Pseudo-labeling) và sự tiến hóa của hàm mục tiêu

Khi mô hình dần hội tụ, khả năng tự dự đoán của nó trên tập dữ liệu không nhãn trở thành một nguồn giám sát mới. Đây là cơ sở của kỹ thuật Pseudo-labeling.

Pseudo-label và ngưỡng tin cậy

Phương pháp giả nhãn nguyên bản của Lee [21] dựa trên giả thuyết rằng các dự đoán có độ tin cậy cao của mô hình thường chính xác. Với một mẫu không nhãn $\mathbf{x}$, giả nhãn $\hat{y}$ được xác định bởi:

$$\hat{y} = \arg \max_k p_k(\mathbf{x}; \theta) \quad \text{với điều kiện} \quad \max_k p_k(\mathbf{x}; \theta) > \tau \quad (2.13)$$

Ở đây, p_k là xác suất đầu ra từ mạng nơ-ron và τ là một ngưỡng cố định (threshold). Việc nạp các $\hat{y}$ này quay lại quá trình huấn luyện giúp mô hình học được các ranh giới quyết định sắc nét hơn (entropy minimization).

FixMatch: Sự kết hợp giữa nhất quán và giả nhãn

FixMatch [22] đã thay đổi tư duy về giả nhãn bằng cách đưa vào khái niệm *Consistency Regularization*. Thuật toán này sử dụng một phiên bản ảnh biến đổi yếu (weakly-augmented) để tạo ra giả nhãn, sau đó ép mô hình phải dự đoán đúng nhãn đó khi đầu vào là một phiên bản biến đổi mạnh (strongly-augmented). Điểm yếu của FixMatch trong bài toán Discovery là sự phụ thuộc vào ngưỡng τ cố định, vốn không phản ánh đúng bản chất của các lớp mới chưa từng xuất hiện trong tập huấn luyện.

2.5.3 Tiếp cận GESNC: Lọc giả nhãn bằng Generalized Entropy (GEN)

Một đóng góp quan trọng của luận văn này là việc thay thế tiêu chí lọc giả nhãn dựa trên xác suất Softmax bằng **Generalized Entropy (GEN)** [10].

Vấn đề về sự quá tự tin của Softmax

Trong bài toán Open-world như GCD, hàm Softmax thường gặp hiện tượng ”quá tự tin”(overconfidence). Khi mô hình gặp một mẫu thuộc lớp mới (OOD), do tính chất chuẩn hóa của Softmax ($\sum p_k = 1$), nó vẫn gán cho mẫu đó một xác suất cao vào một trong các lớp cũ. Điều này dẫn đến việc tạo ra các giả nhãn sai lệch nghiêm trọng, gây nhiễu cho quá trình khám phá.

Ưu điểm lý thuyết của GEN Entropy

Khác với Softmax chỉ quan tâm đến giá trị cực đại, GEN [10] xem xét sự phân phối tổng thể của các logit để đánh giá độ không chắc chắn. GEN đã được chứng minh thực nghiệm là một *indicator* tốt hơn hẳn để phân biệt mẫu thuộc phân phối (In-distribution) và mẫu lạ (Out-of-distribution).

Trong pipeline của **GESNC**, chúng tôi sử dụng giá trị GEN entropy để lọc các

mẫu không nhãn:

- Nếu $\text{GEN}(\mathbf{x}) < \gamma$, mẫu dữ liệu được coi là "đáng tin cậy" và sẽ được gán giả nhãn để tinh chỉnh mô hình.
- Nếu $\text{GEN}(\mathbf{x}) \geq \gamma$, mẫu dữ liệu được coi là thuộc về lớp mới hoặc vùng ranh giới chưa ổn định, và sẽ bị loại bỏ khỏi tập huấn luyện giả nhãn để bảo toàn tính thuần khiết của đặc trưng.

Việc sử dụng GEN giúp hệ thống của chúng tôi tự thích nghi tốt hơn với sự xuất hiện của các danh mục lạ, giảm thiểu rủi ro "sụp đổ mô hình" (model collapse) khi lượng lớp mới chiếm tỷ trọng lớn trong tập dữ liệu. Đây chính là bước đệm quan trọng để thuật toán Selective Neighbor Clustering có thể hoạt động chính xác trên các vùng dữ liệu chưa có nhãn.

Kết luận chương: Sự chuyển dịch từ các ràng buộc cứng cổ điển sang các cơ chế lọc động dựa trên entropy hiện đại đã mở ra hướng đi mới cho việc giải quyết GCD một cách hiệu quả và bền vững hơn.

2.6 Tổng hợp và Định vị Nghiên cứu

Qua quá trình khảo sát các công trình liên quan từ §2.1 đến §2.5, luận văn nhận diện ba khoảng trống nghiên cứu chính thúc đẩy việc phát triển phương pháp GESNC:

1. **GEN chưa được tích hợp vào pipeline GCD.** Liu et al. [10] đã chứng minh rằng Generalized Entropy là một detector OOD vượt trội so với MSP và Energy score trên các benchmark lớn như ImageNet-1k. Tuy nhiên, GEN hiện chỉ được sử dụng như một công cụ đánh giá OOD độc lập — chưa có nghiên cứu nào khai thác GEN để sinh pseudo-labels chất lượng cao phục vụ bài toán khám phá danh mục.

2. **Sự tối ưu chưa triệt để của semi-supervised learning trong SNC.** CiPR [8] đạt hiệu năng mạnh trên GCD nhờ cơ chế Cross-instance Positive Relations và thuật toán SNC. Tuy nhiên, thuật toán SNC gốc trong CiPR vốn là unsupervised learning. Dù phiên bản đầy đủ nhất của CiPR 2024 có kết hợp quan hệ $u-\ell$, nó vẫn chưa tận dụng nhãn thực tế từ tập $\mathcal{D}_l$ để xây dựng các anchor constraints mạnh mẽ. Chính vì phiên bản Full method này đã sử dụng thông tin có nhãn, luận văn quyết định chọn đây làm baseline so sánh trực tiếp ở Chương 3 nhằm đảm bảo tính công bằng cao nhất với cơ chế semi-supervised của GESNC.

3. **Khoảng trống: Thiếu sự kết hợp giữa OOD-aware pseudo-labeling và semi-supervised SNC.** Các phương pháp hiện tại hoặc có cơ chế phát hiện OOD (GEN, Energy) nhưng không áp dụng vào phân cụm, hoặc có thuật toán phân cụm mạnh (SNC, k-means) nhưng thiếu bộ lọc OOD tường minh. Trong phạm vi khảo sát của luận văn, các phương pháp tiêu biểu chưa kết hợp *đồng thời* cả ba thành phần: (i) cổng OOD có cơ sở lý thuyết, (ii) pseudo-labeling từ OOD gate, và (iii) phân cụm semi-supervised với dual-anchor constraints.

Bảng 2.3 tổng hợp sự hiện diện của từng thành phần kỹ thuật trong các phương pháp tiêu biểu, cho thấy rõ vị trí của GESNC là phương pháp được đề xuất nhằm tích hợp đầy đủ cả ba thành phần.

Bảng 2.3: Ma trận so sánh các thành phần kỹ thuật giữa các phương pháp GCD

Phương pháp	OOD Gate	Pseudo-labeling	Semi-supervised SNC
GCD [4]	×	×	×
SimGCD [5]	×	✓	×
GPC [7]	×	×	×
CiPR [8]	×	×	✓
GEN [10] (standalone)	✓	×	×
GESNC (Ours)	✓	✓	✓

Từ bảng trên có thể thấy: GESNC được thiết kế để sở hữu đồng thời cả ba thành phần cốt lõi. Cụ thể, phương pháp đề xuất kế thừa nền tảng phân cụm SNC từ CiPR, bổ sung công lọc GEN entropy (có cơ sở lý thuyết từ [10]) để sinh pseudo-labels chất lượng cao bằng semi-supervised learning thông qua cơ chế dual-anchor pool. Chi tiết kiến trúc toán học của pipeline được trình bày trong Chương 3.

CHƯƠNG 3

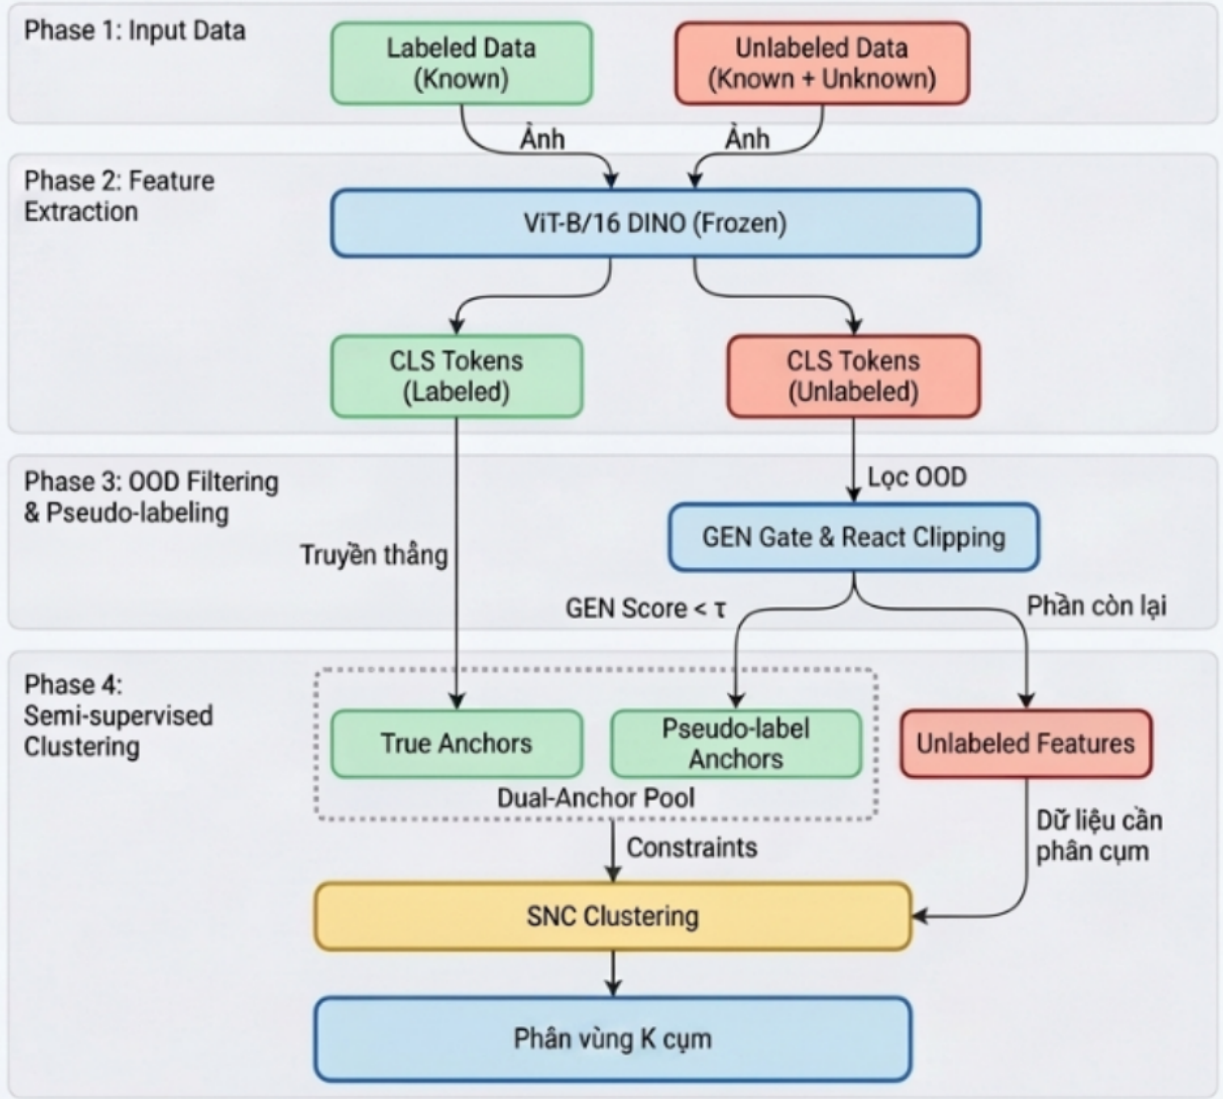
Phương pháp Đề xuất: GESNC

Chương này trình bày toàn bộ kiến trúc kỹ thuật của GESNC (GEN-Augmented Semi-Supervised SNC), một pipeline Generalized Category Discovery được đề xuất trong luận văn này. Pipeline kết hợp ba thành phần cốt lõi: (i) trích xuất đặc trưng bằng backbone ViT-B/16 DINO được đóng băng hoàn toàn, (ii) cổng entropy GEN [10] kết hợp với React feature clipping [11] để sinh pseudo-labels chất lượng cao, và (iii) thuật toán SNC semi-supervised [8] với dual-anchor pool. Mỗi thành phần được trình bày đầy đủ về ký hiệu toán học, công thức, thuật toán và liên kết với mã nguồn triển khai.

3.1 Tổng quan Kiến trúc

Kiến trúc tổng thể của GESNC được minh họa trong Hình 3.1. Pipeline bao gồm 9 giai đoạn từ xử lý dữ liệu đầu vào, trích xuất đặc trưng, học biểu diễn tương phản cho đến phân loại và đánh giá.

KIẾN TRÚC TỔNG THỂ HỆ THỐNG GESNC



Hình 3.1: Sơ đồ luồng xử lý toàn diện của hệ thống GESNC qua 9 giai đoạn (Phases).

Gọi $\mathcal{D}_l = \{(x_i, y_i)\}_{i=1}^{N_l}$ là tập dữ liệu có nhãn với $y_i \in \mathcal{C}^{\text{old}} = \{0, 1, \dots, C_{\text{old}} - 1\}$, và $\mathcal{D}_u = \{x_j\}_{j=1}^{N_u}$ là tập không có nhãn với nhãn ẩn $y_j \in \mathcal{C}^{\text{old}} \cup \mathcal{C}^{\text{new}}$. Mục tiêu của GESNC là phân vùng toàn bộ tập dữ liệu thành K cụm sao cho mỗi cụm tương ứng với một lớp thực sự — đồng thời phân biệt được Known clusters ($y \in \mathcal{C}^{\text{old}}$) và Unknown clusters ($y \in \mathcal{C}^{\text{new}}$).

Bảng 3.1 liệt kê các ký hiệu toán học được sử dụng xuyên suốt chương này cùng với giá trị cụ thể trong hai bộ thực nghiệm CIFAR-100 và CUB-200-2011.

Bảng 3.1: Bảng ký hiệu toán học và giá trị thực nghiệm

Ký hiệu	CIFAR-100	CUB-200	Ý nghĩa
N_l	20.000	~ 1.500	Số mẫu labeled train
N_u	30.000	~ 4.494	Số mẫu unlabeled train
N_{test}	10.000	~ 5.794	Số mẫu test
C_{old}	80	100	Số lớp Known
C_{new}	20	100	Số lớp Unknown
K	100	200	Số cụm mục tiêu
$z \in \mathbb{R}^{768}$		—	CLS token từ ViT-B/16 DINO
$\ell \in \mathbb{R}^{C_{old}}$		—	Logit từ Linear Head
$p \in \Delta^{C_{old}}$		—	Xác suất sau Softmax
$\tilde{h}$		—	Feature sau React clipping
M	16	4	Tham số truncation của GEN
γ	0.05	0.05	Hệ số sharpness của GEN
q	0.99	0.99	Quantile của React clipping
τ		Adaptive	Ngưỡng GEN (percentile PCT%)
sl		$\in \{-101\} \cup \mathcal{C}$	Mảng semi-label anchors
sm		$\in \{0, 1\}$	Anchor mask

3.2 Giai đoạn 1 — Trích xuất Đặc trưng

3.2.1 Tiền xử lý ảnh

CIFAR-100 cung cấp ảnh gốc kích thước 32×32 pixel, trong khi ViT-B/16 DINO [15] yêu cầu đầu vào 224×224 . Để khớp với pipeline CiPR [8] và đảm bảo reproducibility, biến đổi ảnh được áp dụng như sau:

$$x \xrightarrow{\text{Resize}(256)} x' \xrightarrow{\text{CenterCrop}(224)} \hat{x} \xrightarrow{\text{Normalize}(\mu, \sigma)} \hat{\hat{x}}$$

với $\mu = (0.5071, 0.4867, 0.4408)$ và $\sigma = (0.2675, 0.2565, 0.2761)$ là các thống kê của CIFAR-100. Nội suy BICUBIC được sử dụng ở bước Resize để giảm thiểu mờ ảnh khi phóng to ảnh kích thước nhỏ. Với CUB-200-2011, ảnh đã có độ phân giải gốc đủ lớn nên chỉ cần $\text{Resize}(256) \rightarrow \text{CenterCrop}(224)$ và normalize bằng thống kê ImageNet chuẩn ($\mu = (0.485, 0.456, 0.406)$, $\sigma = (0.229, 0.224, 0.225)$).

3.2.2 GCD Split Protocol

Theo chuẩn benchmark GCD [4], tập training được chia thành hai phần: labeled và unlabeled. Mask m_i xác định trạng thái labeled của mỗi mẫu:

$$m_i = \begin{cases} 1 & \text{nếu } y_i \in \mathcal{C}^{\text{old}} \text{ và } i \text{ được chọn ngẫu nhiên (50\%)} \\ 0 & \text{ngược lại} \end{cases} \quad (3.1)$$

Random seed cố định (seed=0) đảm bảo split reproducible qua các lần chạy. Trên CIFAR-100: 20.000 mẫu có nhãn từ 80 Known classes; 30.000 mẫu unlabeled (Known + Unknown).

3.2.3 Trích xuất CLS Token

Backbone ViT-B/16 DINO [15] được giữ hoàn toàn cố định (frozen) trong suốt toàn bộ pipeline. Với mỗi ảnh đầu vào $\hat{x}_i$, CLS token được trích xuất:

$$z_i = f_\theta(\hat{x}_i) \in \mathbb{R}^{768} \quad (3.2)$$

trong đó f_θ là hàm ViT-B/16 với trọng số pretrained cố định ($\nabla_\theta = 0$). Đây là vector đặc trưng 768 chiều tổng hợp ngữ nghĩa toàn ảnh qua cơ chế self-attention của 12 Transformer blocks.

Toàn bộ tham số backbone bị freeze vì hai lý do: (i) tránh catastrophic forgetting các biểu diễn ngữ nghĩa mà DINO đã học trong quá trình self-supervised pretraining, (ii) giảm chi phí tính toán — chỉ cần một lần forward pass qua 60k ảnh là đủ, kết quả lưu vào file .pt để tái sử dụng (extract_features.py).

Trong mã nguồn, freeze được thực hiện bằng:

```
1 for p in model.parameters():
2     p.requires_grad = False
3 model.eval()
```

3.3 Giai đoạn 2 — Linear Classifier Head

3.3.1 Kiến trúc và Huấn luyện

Một lớp tuyến tính $g_\phi : \mathbb{R}^{768} \rightarrow \mathbb{R}^{C_{\text{old}}}$ được đặt trên đỉnh CLS token:

$$\ell_i = g_\phi(z_i) = W z_i + b \quad (3.3)$$

với $W \in \mathbb{R}^{C_{\text{old}} \times 768}$ và $b \in \mathbb{R}^{C_{\text{old}}}$.

Head được huấn luyện với hàm mất mát Cross-Entropy chỉ trên tập labeled $\mathcal{D}_l$:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N_l} \sum_{(x_i, y_i) \in \mathcal{D}_l} \log \frac{\exp(\ell_{i, y_i})}{\sum_{k=0}^{C_{\text{old}}-1} \exp(\ell_{i, k})} \quad (3.4)$$

Siêu tham số huấn luyện: optimizer Adam, learning rate 10^{-3} , weight decay 10^{-4} , 100 epochs, batch size 256 (`main_eval.py`).

3.3.2 Inference trên toàn bộ Dataset

Sau khi huấn luyện, head được inference không gradient trên $\mathcal{D}_{\text{all}} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{test}}$ (60k mẫu CIFAR-100):

$$p_i = \text{softmax}(\ell_i) = \frac{\exp(\ell_i)}{\mathbf{1}^\top \exp(\ell_i)} \in \Delta^{C_{\text{old}}} \quad (3.5)$$

3.3.3 Vai trò trong Pipeline

Linear head không dùng để phân loại cuối cùng. Mục đích thực sự là cung cấp phân phối xác suất p_i làm đầu vào cho hai bước tiếp theo: (i) GEN gate sử dụng p_i để tính entropy score phân biệt Known/Unknown, (ii) $\hat{y}_i = \arg \max_k p_{ik}$ làm pseudo-label cho các mẫu tự tin.

Nhận xét 3.1. *Chất lượng logit của head ảnh hưởng trực tiếp đến độ sạch của pseudo-label pool. Một head kém calibrate (overconfident) sẽ gán nhãn Known sai cho Unknown samples, inject wrong constraints vào SNC. Đây là lý do React (§3.4) được tích hợp như một bước giảm overconfidence trước GEN gate.*

3.4 Giai đoạn 2b — React Feature Clipping

3.4.1 Vấn đề Overconfidence của Softmax

Mạng neural sau nhiều epoch huấn luyện có xu hướng *overconfident*: ngay cả với các mẫu Unknown nằm ngoài phân phối huấn luyện, softmax vẫn trả về xác suất cực đại cao cho một lớp Known nào đó [9]. Điều này gây ra hiện tượng nghiêm trọng trong pipeline GESNC: GEN score của Unknown samples thấp giả tạo → chúng bị lọc vào pseudo-label pool như Known samples → inject wrong cannot-link constraints vào SNC.

Nếu không giải quyết vấn đề overconfidence, GEN score của Unknown samples có thể thấp giả tạo, dẫn đến việc các mẫu này bị lọc sai vào pseudo-label pool như Known samples. Cơ chế React được tích hợp để mitigate hiện tượng này trước khi tính GEN score.

3.4.2 Cơ chế React

React (Rectified Activations) [11] giải quyết vấn đề bằng cách truncate các activation units tại ngưỡng c tính từ tập in-distribution:

$$c = Q_q(\{h_d(x_i) : x_i \in \mathcal{D}_l, d = 1, \dots, 768\}) \quad (3.6)$$

trong đó Q_q là quantile thứ q tính trên tất cả các activation units của tập labeled. Với $q = 0.99$, c là giá trị mà 99% activations của in-distribution samples nằm dưới.

Feature activation sau khi clipping:

$$\tilde{h}(x) = \min(h(x), c) \quad (3.7)$$

trong đó phép min áp dụng element-wise trên vector $h(x) \in \mathbb{R}^{768}$.

3.4.3 Tác động lên phân phối GEN Score

Outlier activations thường xuất hiện ở Known samples khi classifier bị overfit — chúng là nguồn gốc của overconfidence. Sau khi React clip các giá trị này về ngưỡng c :

- **Known samples:** softmax distribution thay đổi nhẹ vì hầu hết activations đã nằm trong dải bình thường.
- **Unknown samples:** các outlier activations vốn gây ra spike giả trong một lớp Known bị truncate, phân phối softmax trở nên phẳng hơn → GEN score tăng → bị lọc khỏi pseudo-label pool.

Trong bộ kết quả hiện tại, React được sử dụng trong cấu hình single-run tốt nhất của GESNC trên CIFAR-100. Tuy nhiên, luận văn không tách riêng đóng góp định lượng của React vì các file kết quả mới chưa cung cấp so sánh cặp đôi có/không React trong cùng điều kiện siêu tham số. React được triển khai ngay sau bước extract features, trước khi linear head thực hiện inference logits.

3.5 Giai đoạn 3 — Tổng GEN Entropy và Pseudo-labeling

3.5.1 Công thức GEN Score

Điểm GEN (Generalized ENtropy) [10] đo mức độ không chắc chắn của mô hình với một mẫu, dựa trên phân phối xác suất sau softmax của các lớp có xác suất cao nhất.

Cho mẫu x_i , bước tính GEN score gồm ba thao tác:

Bước 1 — Softmax. Chuyển logits thành xác suất:

$$p_{i,k} = \frac{\exp(\ell_{i,k})}{\sum_{j=1}^{C_{\text{old}}} \exp(\ell_{i,j})}, \quad k = 1, \dots, C_{\text{old}}$$

Bước 2 — Sorting & Truncation. Sắp xếp xác suất giảm dần và chỉ giữ M giá trị lớn nhất:

$$\hat{p}_{i,(1)} \geq \hat{p}_{i,(2)} \geq \dots \geq \hat{p}_{i,(M)}$$

Truncation tại M loại bỏ nhiều từ các lớp đuôi (tail classes) có xác suất gần 0 nhưng đóng góp noise vào entropy score.

Bước 3 — GEN computation.

$$\mathcal{S}_{\text{GEN}}(x_i; M, \gamma) = \sum_{m=1}^M \hat{p}_{i,(m)}^\gamma \cdot (1 - \hat{p}_{i,(m)})^\gamma \quad (3.8)$$

trong đó $\gamma > 0$ là hệ số sharpness kiểm soát độ nhạy của hàm với sự phân biệt giữa phân phối nhọn và phẳng.

Nhận xét 3.2. Hàm thành phần $g(p) = p^\gamma(1 - p)^\gamma$ đạt cực tiểu khi $p \rightarrow 0$ hoặc $p \rightarrow 1$ (phân phối nhọn $\rightarrow$ GEN thấp $\rightarrow$ Known), và đạt cực đại tại $p = 0.5$ (phân phối phẳng $\rightarrow$ GEN cao $\rightarrow$ Unknown). Khi $\gamma \rightarrow 0$: $g(p) \rightarrow 1$ với mọi p , $\text{GEN} \rightarrow M$ (không phân biệt được). Khi $\gamma = 1$: GEN trở thành tổng entropy nhị phân. Giá trị $\gamma = 0.20$ (CIFAR-100) khuếch đại sự khác biệt giữa Known và Unknown hiệu quả hơn $\gamma = 0.10$.

3.5.2 Chọn tham số M và γ

Qua grid search hệ thống trên $M \in \{4, 8, 16\}$ và $\gamma \in \{0.05, 0.10, 0.20\}$, cấu hình single-run tốt nhất trên CIFAR-100 là $M = 16$, $\gamma = 0.05$. Tuy nhiên, các cấu hình lân cận ($M = 16$, $\gamma = 0.10$ hoặc $\gamma = 0.20$) cho kết quả rất gần nhau, do đó không nên diễn giải đây là ưu thế tuyệt đối của một siêu tham số đơn lẻ.

Lý do chọn $M = 16$: Với $C_{\text{old}} = 80$ lớp Known, việc thiết lập $M = 16$ (thay vì $M = 8$ như bản cũ) cho phép capture một phạm vi đủ rộng các lớp ứng viên để bảo toàn các xác suất ở phần đuôi (tail probabilities) của các mẫu có độ tự tin trung bình. Điều

này giúp tránh việc loại bỏ sớm các lớp Known tiềm năng, trong khi vẫn triệt tiêu hiệu quả nhiều từ 64 lớp còn lại có xác suất gần bằng 0.

Lý do chọn $\gamma = 0.05$: Hệ số sharpness $\gamma = 0.05$ nhỏ giúp hàm số bớt nhạy cảm hơn với các biến động nhỏ trong logits của các lớp top đầu. Điều này đặc biệt quan trọng khi sử dụng đặc trưng DINO từ backbone đóng băng kết hợp với linear head chỉ huấn luyện 100 epochs, nơi phân phối logits chưa hoàn toàn được căn chỉnh tối ưu trên toàn bộ 80 lớp Known. Một γ nhỏ giúp GEN score phân bổ mịn hơn, tạo điều kiện thuận lợi cho việc xác định ngưỡng thích nghi τ theo percentile ổn định hơn.

Với CUB-200-2011 ($C_{\text{old}} = 100$, dataset nhỏ hơn), $M = 4$ và $\gamma = 0.05$ cho kết quả tốt hơn do linear head ít epochs hơn $\rightarrow$ phân phối logit ít sắc nét hơn.

3.5.3 Ngưỡng thích nghi τ

Thay vì dùng ngưỡng cố định, GESNC tính ngưỡng thích nghi dựa trên percentile:

$$\tau = Q_{\text{PCT}}(\{\mathcal{S}_{\text{GEN}}(x_i; M, \gamma)\}_{i=1}^N) \quad (3.9)$$

trong đó N là tổng số mẫu (60k với CIFAR-100 transductive) và PCT là tỉ lệ phần trăm mẫu được chọn làm pseudo-label.

Cơ chế percentile đảm bảo luôn lấy đúng PCT% mẫu có GEN score thấp nhất — tức là tự tin nhất vào Known class — bất kể giá trị tuyệt đối của GEN score thay đổi theo cấu hình.

3.5.4 Sinh Pseudo-labels (Đóng góp mới)

Sau khi có τ , pseudo-labels được gán theo điều kiện:

$$\tilde{y}_i = \begin{cases} \arg \max_k p_{ik} & \text{nếu } \mathcal{S}_{\text{GEN}}(x_i) < \tau \text{ và } m_i = 0 \\ -101 & \text{(unlabeled) ngược lại} \end{cases} \quad (3.10)$$

Điều kiện $m_i = 0$ đảm bảo chỉ inject pseudo-label vào những mẫu *chưa có nhãn thật*, tránh overwrite ground-truth. Điều kiện $\mathcal{S}_{\text{GEN}}(x_i) < \tau$ đảm bảo pseudo-labels chỉ được gán cho các mẫu mà mô hình thực sự tự tin.

Anchor mask được tính là:

$$\text{sm}_i = \mathbf{1}[\text{sl}_i \neq -101] \quad (3.11)$$

Algorithm 1 mô tả đầy đủ quy trình GEN gate.

Algorithm 1: GEN Gate và Pseudo-label Generation

Input :Logits $\{\ell_i\}_{i=1}^N$, labeled mask $\{m_i\}_{i=1}^N$, ground-truth labels $\{y_i : m_i = 1\}$,
tham số M, γ, PCT

Output Mảng semi-labels sl , anchor mask sm

```
:  
// Bước 1: Tính xác suất và GEN score  
1 for  $i = 1$  to  $N$  do  
2    $p_i \leftarrow \text{softmax}(\ell_i);$   
   ; // Eq. 3.5  
3    $\hat{p}_i \leftarrow \text{sort}(p_i, \downarrow);$   
4    $\text{GEN}_i \leftarrow \sum_{m=1}^M \hat{p}_{i,(m)}^\gamma (1 - \hat{p}_{i,(m)})^\gamma;$   
   ; // Eq. 3.8  
  
// Bước 2: Adaptive threshold  
5  $\tau \leftarrow Q_{\text{PCT}}(\{\text{GEN}_i\}_{i=1}^N);$   
   ; // Eq. 3.9  
  
// Bước 3: Khởi tạo và inject labels  
6  $sl \leftarrow -101 \cdot \mathbf{1}_N;$   
   ; // Tất cả unlabeled  
7 for  $i = 1$  to  $N$  do  
8   if  $m_i = 1$  then  
9      $sl[i] \leftarrow y_i;$   
     ; // True anchor  
10  else  
11    if  $\text{GEN}_i < \tau$  then  
12       $sl[i] \leftarrow \arg \max_k p_{ik};$   
      ; // Pseudo-label anchor  
  
13  $sm \leftarrow \mathbf{1}[sl \neq -101];$   
   ; // Eq. 3.11  
14 return  $sl, sm$ 
```

3.6 Giai đoạn 4 — Semi-supervised SNC

3.6.1 Chuẩn hóa L2

Trước khi đưa vào SNC, toàn bộ features được chuẩn hóa L2:

$$\tilde{z}_i = \frac{z_i}{\|z_i\|_2}, \quad \tilde{z}_i \in \mathcal{S}^{767} \quad (3.12)$$

Sau chuẩn hóa, cosine similarity trở thành tích vô hướng: $\cos(\tilde{z}_i, \tilde{z}_j) = \tilde{z}_i^\top \tilde{z}_j$, cho phép tính toán hiệu quả và ổn định số học.

3.6.2 Xây dựng Đồ thị 1-NN

Hàm `clust_rank()` xây dựng đồ thị láng giềng gần nhất. Với mỗi điểm i , láng giềng gần nhất được xác định bởi khoảng cách cosine:

$$D_{ij} = 1 - \tilde{z}_i^\top \tilde{z}_j, \quad r_i = \arg \min_{j \neq i} D_{ij}$$

Ma trận kề 1-NN được xây dựng: $A[i, r_i] = 1$, các phần tử còn lại bằng 0.

Với $N \leq 100,000$ samples (trường hợp CIFAR-100 60k): pairwise distance matrix được tính exact. Với $N > 100,000$: PyNNDescent ANN được sử dụng để tránh OOM.

3.6.3 Inject Semi-supervised Constraints (Đóng góp mới)

Đây là điểm khác biệt cơ bản so với CiPR: dù phiên bản 2024 đã tận dụng quan hệ u - ℓ , GESNC bổ sung thêm hard anchor constraints từ labeled data và GEN pseudo-labels. GESNC inject hai loại constraints dựa trên anchor pool $\mathcal{A} = \{i : \text{sm}[i] = 1\}$:

Must-link constraints. Các anchors cùng nhãn y được kết nối thành chuỗi tuần

tự theo khoảng cách tăng dần. Với class k có $|\mathcal{A}_k|$ anchors:

$$r[\text{anchor}_t^{(k)}] = \text{anchor}_{t+1}^{(k)}, \quad t = 1, \dots, N_{\text{chain}} - 1$$

Độ dài chuỗi tối đa: $N_{\text{chain}} = \lceil \sqrt{|\mathcal{A}_k|} \rceil$. Giới hạn này tránh tạo chuỗi quá dài làm méo cấu trúc cluster.

Cannot-link constraints. Hai anchors khác nhãn bị ngắt kết nối trong ma trận kề:

$$A[i, j] = 0 \quad \forall i, j \in \mathcal{A} : \text{sl}[i] \geq 0, \text{sl}[j] \geq 0, \text{sl}[i] \neq \text{sl}[j] \quad (3.13)$$

3.6.4 Graph Propagation và Connected Components

Sau khi inject constraints, ma trận kề được mở rộng:

$$\bar{A} = (A + I)(A + I)^\top \quad (3.14)$$

Về mặt ngữ nghĩa, $[\bar{A}]_{ij} > 0$ khi và chỉ khi i và j cùng chia sẻ ít nhất một hàng xóm — cơ chế *second-order connectivity* giúp lan truyền thông tin cluster qua 2 bước thay vì 1, tạo cụm bền vững hơn.

Đường chéo $\bar{A}$ được đặt về 0, sau đó thuật toán connected components (`scipy.sparse.csgraph`) trả về phân hoạch P_0 với hàng nghìn clusters.

3.6.5 Partition Hierarchy

SNC lặp lại quá trình phân cụm theo hướng top-down: Centroids của P_0 trở thành input của vòng tiếp theo, tạo ra $P_1, P_2, \dots$ với số clusters giảm dần. Quá trình dừng khi số clusters không giảm thêm (`ensure_early_exit=True`).

3.6.6 Điều chỉnh về K Clusters

Từ tập phân hoạch $\{P_0, P_1, \dots\}$, hàm `req_numclust()` tìm phân hoạch P_k gần nhất có $|P_k| \geq K$, sau đó merge từng cặp centroid gần nhau nhất cho đến khi đạt đúng K :

$$\text{Merge}(c_a, c_b) \quad \text{khi } d(c_a, c_b) = \min_{i \neq j} d(c_i, c_j)$$

Algorithm 2 mô tả đầy đủ Semi-supervised SNC.

Algorithm 2: Semi-supervised SNC (GESNC)

Input : $\{\tilde{z}_i\}_{i=1}^N$ (L2-normalized features), semi-labels sl , anchor mask sm , K (số clusters), distance metric d

Output Cluster assignments $\hat{y} \in \{0, \dots, K-1\}^N$

:

// Bước 1: Xây 1-NN graph với anchor constraints

1 $A, D \leftarrow \text{clust_rank}(\tilde{Z}, sl, sm);$ // Must-link injected

2 $\bar{A} \leftarrow (A + I)(A + I)^\top;$ // Second-order connectivity, Eq. 3.14

// Bước 2: Cannot-link

3 **for** $(i, j) \in \mathcal{A} \times \mathcal{A} : sl[i] \neq sl[j]$ **do**

4 $\bar{A}[i, j] \leftarrow 0;$ // Eq. 3.13

5 $\bar{A}.\text{setdiag}(0);$

// Bước 3: Partition hierarchy

6 $u_0, n_0 \leftarrow \text{connected_components}(\bar{A});$

7 $c \leftarrow u_0; \mathcal{M} \leftarrow \text{centroids}(\tilde{Z}, u_0);$

8 $k \leftarrow 1; \text{num_clust} \leftarrow [n_0];$

9 **while** $\text{exit_clust} > 1$ **do**

10 $A_k, D_k \leftarrow \text{clust_rank}(\mathcal{M}, sl^{(k)}, sm^{(k)});$

11 $u_k, n_k \leftarrow \text{connected_components}(A_k, D_k);$

12 $c \leftarrow [c \parallel u_k]; \mathcal{M} \leftarrow \text{centroids}(\tilde{Z}, c_{:, -1});$

13 $\text{exit_clust} \leftarrow \text{num_clust}[-1] - n_k; \text{num_clust.append}(n_k); k \leftarrow k + 1;$

// Bước 4: Điều chỉnh về K clusters

14 $\text{ind} \leftarrow \max\{k : \text{num_clust}[k] \geq K\};$

15 $\hat{y} \leftarrow \text{req_numclust}(c[:, \text{ind}], \tilde{Z}, K, d, sl, sm);$

16 **return** $\hat{y}$

3.7 Giai đoạn 5 — Đánh giá: Hungarian Matching

3.7.1 Bài toán gán nhãn tối ưu

SNC trả về cluster assignments $\hat{y} \in \{0, \dots, K-1\}^N$ với cluster IDs tùy ý — không nhất thiết tương ứng với class labels. Thuật toán Hungarian [23] tìm phép gán tối ưu (bijection) giữa K cluster IDs và K class labels.

Ma trận tần suất $W \in \mathbb{Z}_{\geq 0}^{K \times K}$ được xây dựng:

$$W[i, j] = \#\{x : \hat{y}(x) = i, y(x) = j\} \quad (3.15)$$

Phép gán tối ưu σ^* được tìm bằng:

$$\sigma^* = \arg \max_{\sigma \in \mathcal{P}(K)} \sum_{i=0}^{K-1} W[i, \sigma(i)] \quad (3.16)$$

Trong thực tế: `scipy.optimize.linear_sum_assignment(W.max() - W)` chuyển bài toán maximization thành minimization. Độ phức tạp: $\mathcal{O}(K^3) = \mathcal{O}(100^3)$ — rất nhanh.

3.7.2 Các chỉ số đánh giá

All ACC — Độ chính xác tổng thể trên N_{test} mẫu test:

$$\text{ACC}_{\text{all}} = \frac{1}{N_{test}} \sum_{i=0}^{K-1} W[i, \sigma^*(i)] \quad (3.17)$$

Old ACC — Độ chính xác riêng trên Known class test samples:

$$\text{ACC}_{\text{old}} = \frac{\sum_{(i,j) \in \sigma^*} \#\{x : \hat{y}(x) = i, y(x) = j, y \in \mathcal{C}^{\text{old}}\}}{|\{x_{test} : y \in \mathcal{C}^{\text{old}}\}|} \quad (3.18)$$

New ACC — Độ chính xác riêng trên Unknown class test samples:

$$ACC_{\text{new}} = \frac{\sum_{(i,j) \in \sigma^*} \#\{x : \hat{y}(x) = i, y(x) = j, y \in \mathcal{C}^{\text{new}}\}}{|\{x_{\text{test}} : y \in \mathcal{C}^{\text{new}}\}|} \quad (3.19)$$

H-score — Harmonic mean của Old và New ACC:

$$H = \frac{2 \cdot ACC_{\text{old}} \cdot ACC_{\text{new}}}{ACC_{\text{old}} + ACC_{\text{new}}} \quad (3.20)$$

H-score sử dụng harmonic mean thay vì arithmetic mean vì nó phạt nặng khi một trong hai thành phần thấp. Ví dụ: Old=90%, New=5% $\rightarrow$ H-score = 9.5%, phản ánh đúng rằng mô hình thất bại trong việc khám phá Unknown classes dù nhận diện Known tốt.

3.8 Phân tích độ phức tạp tính toán

Bảng 3.2 tóm tắt độ phức tạp thời gian và không gian của từng bước trong pipeline GESNC.

Bảng 3.2: Phân tích độ phức tạp tính toán của GESNC

Bước	Time	Space	Ghi chú
Feature extraction	$\mathcal{O}(N \cdot L \cdot d^2)$	$\mathcal{O}(N \cdot d)$	$L = 12, d = 768$; chạy 1 lần, cache
React clipping	$\mathcal{O}(N \cdot d)$	$\mathcal{O}(d)$	Trivial
Linear head train	$\mathcal{O}(N_l \cdot d \cdot C_{\text{old}} \cdot E)$	$\mathcal{O}(d \cdot C_{\text{old}})$	$E = 100$ epochs
GEN computation	$\mathcal{O}(N \cdot C_{\text{old}} \log C_{\text{old}})$	$\mathcal{O}(N)$	Do sorting
SNC 1-NN (exact)	$\mathcal{O}(N^2 \cdot d)$	$\mathcal{O}(N^2)$	$N = 60k$: chấp nhận được
req_numclust	$\mathcal{O}(n_a^2 \cdot d \cdot \Delta K)$	$\mathcal{O}(n_a^2)$	Bottleneck chính
Hungarian matching	$\mathcal{O}(K^3)$	$\mathcal{O}(K^2)$	$K = 100$: rất nhanh

Bottleneck chính — req_numclust: Bước `req_numclust()` trong SNC tính pairwise distance trên toàn bộ anchor pool $n_a = |\mathcal{A}|$. Với $n_a = 23,513$ anchors (CIFAR-100, PCT=10, React $q = 0.99$):

$$\text{Mem} = n_a^2 \times 4 \text{ bytes} = 23513^2 \times 4 \approx \mathbf{2.2 \text{ GB RAM}} \quad (3.21)$$

Trong các thực nghiệm của luận văn, bước này chạy trong khoảng $\Delta K = 100 - n_a^{(P)}$ lần merge (với $n_a^{(P)}$ là số clusters trong phân hoạch gần nhất $\geq K$), mỗi lần tính một pairwise distance matrix trên centroids. Chi phí thực tế do đó nhỏ hơn worst-case nhờ số centroids giảm nhanh theo hierarchy.

Hướng cải thiện: Nếu mở rộng sang dataset lớn (ImageNet-100, $\sim 130k$ samples),

n_a có thể vượt 50k $\rightarrow$ OOM. Giải pháp đề xuất: anchor subsampling ($n' \ll n_a$) hoặc mini-batch merge với Approximate Nearest Neighbor (xem §5.3.4).

3.9 Tóm tắt Pipeline

Bảng 3.3 tóm tắt toàn bộ pipeline GESNC với file triển khai tương ứng.

Bảng 3.3: Tóm tắt 5 giai đoạn pipeline GESNC

Phase	Tên	Output	File
1	Feature Extraction	$z \in \mathbb{R}^{768}$ cho 60k mẫu	<code>extract_features.py</code>
2	Linear Head	Logits ℓ , probs p cho 60k mẫu	<code>main_eval.py</code>
2b	React Clipping	Calibrated activations $\tilde{h}$	<code>main_eval.py</code>
3	GEN Gate	sl, sm — dual-anchor pool ($\sim 23.5k$)	<code>gen_entropy.py</code>
4	Semi-SNC	Cluster assignments $\hat{y} \in \{0, \dots, 99\}^{60k}$	<code>clustering.py</code>
5	Hungarian Eval	All/Old/New ACC, H-score	<code>metrics.py</code>

Các đóng góp mới của luận văn so với CiPR [8] gốc tập trung ở Phase 2b (React) và Phase 3 (GEN pseudo-labeling thay vì chỉ OOD filtering). Phase 4 kế thừa cơ chế SNC từ CiPR nhưng chuyển sang chế độ semi-supervised nhờ dual-anchor pool từ Phase 3.

CHƯƠNG 4

Thực nghiệm và Đánh giá

4.1 Thiết lập Thực nghiệm

4.1.1 Tập dữ liệu

Luận văn tiến hành thực nghiệm trên hai benchmark chuẩn của bài toán GCD: **CIFAR-100** [24] và **CUB-200-2011** [25].

CIFAR-100 gồm 60.000 ảnh phân thành 100 lớp (600 ảnh/lớp), kích thước gốc 32×32 pixel. Theo GCD split chuẩn [4], 80 lớp đầu tiên được chọn làm Known (C^{old}) và 20 lớp còn lại làm Unknown (C^{new}), với 50% samples Known trong tập train được chọn ngẫu nhiên (seed=0) làm labeled — tương đương 20.000 anchors có nhãn thật.

CUB-200-2011 gồm 11.788 ảnh thuộc 200 loài chim (trung bình ~59 ảnh/lớp), kích thước 224×224. Theo split GCD chuẩn, 100 lớp đầu là Known và 100 lớp còn lại là Unknown, dữ liệu được remap theo `cub_osr_splits.pkl`. Tổng cộng ~5.994 ảnh training và ~5.794 ảnh test.

Bảng 4.1: Thống kê hai tập dữ liệu theo GCD split protocol

Dataset	Split	Classes	Train Lab.	Train Unlab.	Test
CIFAR-100	Known	80	20.000	20.000	8.000
	Unknown	20	–	10.000	2.000
CUB-200-2011	Known	100	~1.500	~1.500	~2.897
	Unknown	100	–	~2.994	~2.897

4.1.2 Môi trường Triển khai

CIFAR-100 được thực nghiệm trên **Kaggle Notebook** với GPU NVIDIA Tesla T4 (16 GB GDDR6). CUB-200-2011 được fine-tune trên **Google Cloud VM** (NVIDIA T4) với 200 epochs; bước đánh giá feature-level chạy trên CPU do lỗi cublasLtCreate khi forward ViT qua GPU tại inference.

Bảng 4.2: Môi trường và cấu hình thực nghiệm

Thành phần	CIFAR-100 (Kaggle)	CUB-200 (GCloud VM)
GPU	NVIDIA Tesla T4, 16 GB	NVIDIA Tesla T4, 16 GB
RAM	29 GB	16 GB
Python	3.12	3.10
PyTorch	2.x	2.1.2 (CUDA 11.8)
Backbone	ViT-B/16 DINO, frozen	ViT-B/16 DINO, fine-tuned 200 ep
Clustering	SciPy, sklearn NN	SciPy, sklearn NN

4.1.3 So sánh Điều kiện Thực nghiệm với CiPR

Bảng 4.3 tổng hợp các điều kiện thực nghiệm chính, làm rõ sự tương đồng và khác biệt giữa CiPR gốc [8] và GESNC nhằm đảm bảo tính công bằng khi so sánh.

Bảng 4.3: So sánh điều kiện thực nghiệm giữa CiPR [8] và GESNC trên CIFAR-100

Yếu tố	CiPR (Table 6, Row 3)	GESNC (luận văn)
Backbone	ViT-B/16 DINO	ViT-B/16 DINO
Chế độ backbone	Fine-tuned	Frozen
GCD Split	Standard (seed cố định)	Standard (seed=0)
Protocol	Transductive	Transductive
Dữ liệu sử dụng	$\mathcal{D}_l + \mathcal{D}_u$	$\mathcal{D}_l + \mathcal{D}_u$
Tỉ lệ labeled	50%	50%
Oracle K	100	100
Pseudo-labeling	Không	Có (GEN + React)

Lưu ý quan trọng: CiPR fine-tune toàn bộ backbone, trong khi GESNC giữ backbone hoàn toàn frozen. Sự khác biệt này có lợi cho GESNC về chi phí tính toán, nhưng CiPR có thể khai thác đặc trưng tốt hơn do được tinh chỉnh cho tập dữ liệu cụ thể. Hai phương pháp sử dụng cùng GCD split protocol và Oracle K , đảm bảo tính so sánh được về thiết lập bài toán.

4.1.4 Siêu tham số

Bảng 4.4: Siêu tham số của pipeline GESNC trên hai dataset

Module	Tham số	CIFAR-100	CUB-200
Backbone	Image size	224×224 (resize từ 32)	224×224
	Labeled frac	50% ($\approx 20k$)	50% ($\approx 1.5k$)
Classifier	Optimizer	Adam	SGD + momentum
	LR	10^{-3}	0.1 (cosine, warmup 10 ep)
	Epochs	100	200
	Batch size	256	128
GEN Gate	M (best)	16	4
	γ (best)	0.05	0.05 – 0.10
	PCT (best)	10%	5% (no React)
	React q	0.99 ($\checkmark$)	0.99 (marginal)
SNC	Distance	Cosine	Cosine
	K (train)	100	100
	K (eval)	100	200

4.1.5 Hai Protocol Đánh giá

Luận văn sử dụng hai protocol để phân tích đa chiều:

Protocol 1 — Strict Train-only. SNC chạy chỉ trên tập training (50k CIFAR-100 / $\sim 6k$ CUB-200). Kết quả được báo cáo trên *unlabeled training samples* (Known unlabeled + Unknown). Protocol này nghiêm ngặt nhất, tránh data leakage, và phù hợp để so sánh trực tiếp với CiPR.

Protocol 2 — Transductive. SNC chạy trên toàn bộ 60k (train + test) cho CIFAR-100, hoặc $\sim 12k$ cho CUB-200. Nhãn test tuyệt đối không được dùng khi xây dựng anchor pool. Kết quả được báo cáo riêng biệt trên unlabeled train và test set. Protocol này khai thác global cluster structure, hướng đến deployment thực tế hơn.

Pseudo-label anchors được tạo bởi GEN score với tham số (M, γ) và threshold thích nghi $\tau = Q_{\text{PCT}}$ (Eq. 3.8). Tùy chọn **React** [11] clip activation units tại quantile $q = 0.99$ trước khi đưa vào linear head, nhằm giảm overconfidence của softmax với Unknown samples.

4.2 Kết quả trên CIFAR-100

4.2.1 So sánh với Baseline CiPR

Bảng 4.5 trình bày kết quả CIFAR-100 theo hai nhóm: (i) baseline reproduction của CiPR và (ii) các cấu hình GESNC có bổ sung GEN/React. Trong cấu hình PCT=0 và React=False, pipeline thực nghiệm được thiết lập tương đương với phương pháp CiPR gốc. Cụ thể, thành phần PCT không được kích hoạt và cơ chế React cũng không được sử dụng. Do đó, pipeline chỉ thực hiện quy trình đánh giá theo thiết lập của CiPR, với đặc trưng được trích xuất thông qua backbone đã được đóng băng. Backbone này không được huấn luyện lại trong quá trình đánh giá.

Để kiểm chứng tính tương đương, mã nguồn CiPR gốc đã được clone và chạy lại trong cùng điều kiện thực nghiệm; kết quả thu được trùng khớp với kết quả của pipeline ở cấu hình PCT=0, React=False. Vì vậy, cấu hình này được sử dụng như một baseline reproduction nhằm kiểm tra tính đúng đắn của pipeline thực nghiệm.

Bảng 4.5: Baseline reproduction CiPR và cấu hình GESNC single-run tốt nhất trên CIFAR-100

Cấu hình	PCT	React	All	Old	New	H-score
CiPR reproduction / sanity check	0	No	84.95%	87.17%	80.52%	83.71%
GESNC best single-run	10	Yes	84.97%	85.69%	83.53%	84.59%

Dòng CiPR reproduction là baseline tắt định lấy từ `results/cifar100_multi_seed_final.csv` và `results/multi_seed_full.log`. Dòng GESNC best single-run lấy từ `gcd_gesnc_cifar100_results.csv`: $M = 16$, $\gamma = 0.05$, PCT=10, React $q = 0.99$, với 3.513 pseudo-label anchors.

Bảng 4.5 dùng cùng baseline CiPR reproduction với Bảng 4.6. Riêng dòng GESNC trong Bảng 4.5 là cấu hình single-run tốt nhất trong grid search mới, còn Bảng 4.6 đánh giá độ ổn định qua nhiều hạt giống.

Bảng 4.6: Đánh giá đa hạt giống trên CIFAR-100 (mean $\pm$ standard deviation)

Cấu hình	All ACC	Old ACC	New ACC	H-score
CiPR reproduction (PCT=0, no React)	84.95 $\pm$ 0.00	87.17 $\pm$ 0.00	80.52 $\pm$ 0.00	83.71 $\pm$ 0.00
GESNC (PCT=10, GEN+React)	84.11 $\pm$ 0.17	85.69 $\pm$ 0.05	80.96 $\pm$ 0.61	83.25 $\pm$ 0.30
Δ GESNC – baseline	−0.84	−1.48	+0.44	−0.46
p -value	0.0004	< 0.001	0.1844	0.0265

Lưu ý: Đối với cấu hình CiPR reproduction, do backbone được đóng băng và thuật toán SNC trong thiết lập này hoạt động theo hướng tắt định, việc thay đổi seed không làm thay đổi kết quả, dẫn đến độ lệch chuẩn bằng 0.00.

Kết quả đa hạt giống cho thấy GESNC không cải thiện đồng đều trên mọi chỉ số

so với baseline reproduction của CiPR. Lợi ích chính nằm ở New ACC, nhưng mức tăng này chưa có ý nghĩa thống kê ($p = 0.1844$). Vì vậy, các kết quả CIFAR-100 được diễn giải theo hướng trade-off giữa Old ACC và New ACC, thay vì khẳng định cải thiện tuyệt đối trên toàn bộ chỉ số.

4.2.2 Kết quả trên Test Set CIFAR-100

Bảng 4.7 báo cáo kết quả trên 10.000 mẫu test theo grid search M và γ với PCT=10, React $q = 0.99$, protocol transductive. Test set không tham gia vào quá trình xây dựng pseudo-labels.

Bảng 4.7: Grid search M và γ trên Test Set CIFAR-100 (PCT=10, React $q=0.99$, protocol transductive)

M	γ	All	Old	New	H-score
4	0.05	80.24%	83.40%	67.60%	74.67%
4	0.10	80.26%	83.43%	67.60%	74.68%
4	0.20	80.49%	83.44%	68.70%	75.35%
8	0.05	80.45%	83.38%	68.75%	75.36%
8	0.10	80.43%	83.36%	68.70%	75.32%
8	0.20	80.46%	83.40%	68.70%	75.34%
16	0.05	80.55%	83.50%	68.75%	75.41%
16	0.10	80.51%	83.45%	68.75%	75.39%
16	0.20	80.45%	83.39%	68.70%	75.33%

Best: $M = 16$, $\gamma = 0.05$ (All=80.55%, H=75.41%).

Đã kiểm chứng bằng file `single-run result/gcd_gesnc_cifar100_results.csv`.

Trên test set, mô hình đạt **All ACC = 80.55%**, **New ACC = 68.75%** và **H-score = 75.41%**. Khoảng cách giữa unlabeled train và test phản ánh việc test samples không

tham gia vào quá trình xây dựng anchor pool, dẫn đến thông tin clustering ít phong phú hơn. Kết quả test set ổn định cao qua các cấu hình M và γ (dao động $< 0.55\%$ All ACC), cho thấy pipeline robust với lựa chọn siêu tham số GEN.

4.3 Phân tích Ablation — CIFAR-100

4.3.1 Ablation 1 — Ảnh hưởng của PCT (Pseudo-label Threshold)

Bảng 4.8 khảo sát ảnh hưởng của tham số PCT — ngưỡng percentile xác định lượng pseudo-label anchors. Dòng PCT=0 sử dụng baseline CiPR reproduction đã thống nhất với Bảng 4.5 và Bảng 4.6; các dòng PCT > 0 được lấy từ file single-run mới `results/gcd_gesnc_cifar100_results.csv` với $M = 16$ và $\gamma = 0.05$.

Bảng 4.8: Ablation PCT trên CIFAR-100 với baseline CiPR thống nhất và các dòng PCT > 0 từ kết quả single-run mới

PCT	Pseudo	All	Old	New	H-score
0	0	84.95%	87.17%	80.52%	83.71%
5	1746	84.42%	85.77%	81.72%	83.69%
10	3513	84.97%	85.69%	83.53%	84.59%
15	5239	84.33%	85.81%	81.37%	83.53%
20	6957	84.92%	85.77%	83.23%	84.48%

Trong PCT sweep mới, cấu hình PCT=10 đạt New ACC và H-score cao nhất, trong khi baseline PCT=0 đạt Old ACC cao nhất. Khi tăng lên PCT=15, cả All ACC, New ACC và H-score đều giảm rõ rệt; PCT=20 phục hồi gần mức PCT=10 nhưng không vượt qua cấu hình tốt nhất về H-score. Vì đây là kết quả single-run, luận văn không diễn giải PCT=10 như một kết luận thống kê mạnh mà chỉ xem đây là cấu hình cân bằng Old/New tốt nhất trong grid hiện có.

4.3.2 Ablation 2 — Ảnh hưởng của React Feature Clipping

Ba file kết quả mới không cung cấp một so sánh cặp đôi giữa $\text{React}=\text{True}$ và $\text{React}=\text{False}$ trong cùng điều kiện M , γ và PCT. Vì vậy, bảng React ablation cũ không được giữ lại trong phiên bản kết quả này để tránh trộn số liệu từ các lần chạy khác nhau. Không đủ thông tin để kết luận từ dữ liệu mới về ảnh hưởng độc lập của React trên CIFAR-100.

Trong các kết quả single-run mới, cấu hình GESNC tốt nhất sử dụng React với $q = 0.99$ cùng PCT=10, $M = 16$ và $\gamma = 0.05$. Do đó, React được trình bày như một thành phần của cấu hình tốt nhất hiện có, thay vì một kết luận ablation độc lập. Nếu muốn khẳng định vai trò riêng của React, cần bổ sung thí nghiệm có/không React dưới cùng một thiết lập siêu tham số và cùng protocol đánh giá.

4.3.3 Ablation 3 — Grid Search M và γ

Bảng 4.9 trình bày full grid search $M \in \{4, 8, 16\}$ và $\gamma \in \{0.05, 0.10, 0.20\}$ với PCT=10, React $q = 0.99$, protocol transductive — báo cáo trên unlabeled train.

Bảng 4.9: Grid search M và γ — unlabeled train, protocol transductive (CIFAR-100, PCT=10, React $q=0.99$)

M	γ	Pseudo	All	Old	New	H-score
4	0.05	3505	84.40%	85.71%	81.77%	83.69%
4	0.10	3509	84.38%	85.69%	81.77%	83.68%
4	0.20	3507	84.85%	85.59%	83.37%	84.47%
8	0.05	3511	84.65%	86.63%	80.69%	83.56%
8	0.10	3512	84.61%	86.59%	80.64%	83.51%
8	0.20	3513	84.89%	85.74%	83.18%	84.44%
16	0.05	3513	84.97%	85.69%	83.53%	84.59%
16	0.10	3513	84.95%	85.66%	83.52%	84.58%
16	0.20	3527	84.95%	85.68%	83.50%	84.58%

Đã kiểm chứng bằng file single-run results/gcd_gesnc_cifar100_results.csv.

Trong grid search single-run mới, cấu hình $M = 16$, $\gamma = 0.05$ đạt All ACC và H-score cao nhất trên unlabeled train. Tuy nhiên, khoảng cách giữa các cấu hình $M = 16$ là rất nhỏ, do đó không nên diễn giải đây là ưu thế tuyệt đối của một siêu tham số đơn lẻ.

4.4 Kết quả trên CUB-200-2011

4.4.1 Strict Train-only — PCT Sweep

Bảng 4.10 báo cáo kết quả trên unlabeled training set của CUB-200-2011 với checkpoint `final.pth` (200 epochs), $M = 8$, $\gamma = 0.1$, không React.

Bảng 4.10: PCT sweep — strict train-only, CUB-200-2011 ($M = 8$, $\gamma = 0.1$, no React)

PCT	Anchors	All	Old	New	H	Ghi chú
0 (Pure SNC)	1.500	59.08%	62.93%	57.16%	59.90%	
5	1.633	59.26%	63.79%	56.99%	60.20%	Best All
10	1.774	59.17%	64.33%	56.59%	60.21%	Best Old, Best H
15	1.882	58.99%	64.20%	56.39%	60.04%	
20	1.986	58.77%	64.26%	56.02%	59.86%	

Trên CUB-200-2011, pseudo-labeling nhẹ (PCT=5 hoặc PCT=10) mang lại cải thiện nhỏ so với Pure SNC: All ACC tăng 0.18% (PCT=5) và H-score tăng 0.31% (PCT=10). Khi $PCT \geq 15$, All/New ACC giảm — pattern tương tự CIFAR-100.

4.4.2 Ảnh hưởng của React trên CUB-200-2011

Bảng 4.11 so sánh trực tiếp GEN với và không có React trên CUB-200, strict train-only, PCT=15.

Bảng 4.11: So sánh GEN vs GEN+React — strict train-only, CUB-200-2011, PCT=15

Biến thể (M, γ)	Anchors	All	Old	New	H
GEN (không React; $M = 8, \gamma = 0.1$)	1.882	58.99%	64.20%	56.39%	60.04%
GEN + React ($M = 4, \gamma = 0.05$)	1.879	58.97%	64.60%	56.16%	60.08%
GEN + React ($M = 4, \gamma = 0.10$)	1.879	58.97%	64.60%	56.16%	60.08%
GEN + React ($M = 16, \gamma = 0.05$)	1.886	58.92%	63.79%	56.49%	59.92%

Trái với CIFAR-100, **React không mang lại lợi thế rõ ràng trên CUB-200**: All ACC và New ACC của no-React nhỉnh hơn (+0.02% và +0.23%), chỉ Old ACC tăng nhẹ với React (+0.40%). Điều này cho thấy backbone fine-tuned 200 epochs trên CUB-200

đã có calibration tốt hơn so với linear head 100 epochs của CIFAR-100, nên React ít ảnh hưởng đến phân phối GEN score hơn.

4.4.3 Kết quả Transductive trên CUB-200-2011

Bảng 4.12 trình bày kết quả protocol transductive trên cả unlabeled train và test set của CUB-200-2011.

Bảng 4.12: Kết quả transductive (train+test) — CUB-200-2011 ($M = 8$, $\gamma = 0.1$). Đơn vị: %.

PCT	React	Unlabeled Train				Test Set			
		All	Old	New	H	All	Old	New	H
0	No	58.50	69.33	53.07	60.12	61.46	70.53	52.59	60.26
5	No	57.92	65.20	54.29	59.24	61.84	76.87	46.94	58.29
10	No	58.19	63.93	55.32	59.31	61.72	76.49	47.08	58.28
15	No	58.41	63.79	55.72	59.49	61.86	75.55	48.28	58.92
20	No	58.46	65.40	54.99	59.74	61.96	75.49	48.56	59.10
5	Yes	58.28	65.73	54.55	59.62	62.17	76.66	47.80	58.89
10	Yes	58.52	64.13	55.72	59.63	61.98	76.49	47.59	58.68
15	Yes	58.08	63.86	55.19	59.21	61.65	75.52	47.90	58.62
20	Yes	58.39	64.86	55.16	59.62	61.70	75.07	48.45	58.89

Để đánh giá độ ổn định và ý nghĩa thống kê của phương pháp trên CUB-200-2011, Bảng 4.13 trình bày kết quả đánh giá đa hạt giống (3 seeds $\{0, 1, 2\}$) trên protocol transductive, so sánh giữa baseline CiPR reproduction (PCT=0, no React) và cấu hình GESNC (PCT=10, $M = 8$, $\gamma = 0.1$, no React).

Bảng 4.13: Đánh giá đa hạt giống trên CUB-200-2011

Cấu hình	All ACC	Old ACC	New ACC	H-score
CiPR reproduction (PCT=0, no React)	58.50 ± 0.00	69.33 ± 0.00	53.07 ± 0.00	60.12 ± 0.00
GESNC (PCT=10, GEN, no React)	58.92 ± 0.12	70.40 ± 0.37	53.17 ± 0.00	60.59 ± 0.14
Δ GESNC – baseline	+0.42	+1.07	+0.10	+0.46
p -value	0.0275	0.0381	< 0.001	0.0283


Kết quả ở Bảng 4.13 được báo cáo trên unlabeled train và khớp với dòng PCT=0, no React trong Bảng 4.12. GESNC đem lại cải thiện nhỏ trên CUB-200-2011: All ACC tăng 0.42% ($p = 0.0275$), Old ACC tăng 1.07% ($p = 0.0381$), New ACC tăng 0.10% ($p < 0.001$), và H-score tăng 0.46% ($p = 0.0283$). Riêng New ACC cần được diễn giải thận trọng vì file kết quả ghi độ lệch chuẩn bằng 0.00 cho cả hai cấu hình; do đó, luận văn chỉ xem đây là cải thiện nhỏ trong các seed đã chạy, không phải bằng chứng về một mức tăng lớn trên Unknown classes.

Với protocol transductive, React giúp Test All ACC đạt **62.17%** (PCT=5) — cao hơn no-React tốt nhất (61.96% tại PCT=20). Tuy nhiên Test New ACC vẫn dưới 49% ở tất cả configurations, phản ánh độ khó đặc trưng của CUB-200 (fine-grained, K=200, dataset nhỏ).


Điểm nổi bật: với transductive no-React (PCT=20), Test H-score đạt 59.10% — thấp hơn strict train-only tốt nhất (60.21%) chỉ 1.11%, cho thấy hai protocol cho kết quả khá tương đương trên CUB-200. Trong khi transductive có lợi thế Test All ACC (61.96% vs $\sim 59.26\%$ train-only All), strict train-only cho H-score nhỉnh hơn nhờ New ACC cao hơn (57.16% vs $\sim 49\%$).

4.5 Phân tích Định tính


Qua quan sát định tính, chúng tôi minh họa 3 khía cạnh quan trọng của mô hình trên tập CIFAR-100: phân phối GEN score, không gian biểu diễn t-SNE, và độ tinh khiết của các cụm (cluster purity).



Hình 4.1: Phân phối GEN score của Known và Unknown classes trên CIFAR-100. Đường đứt nét màu đỏ thể hiện ngưỡng τ tại PCT=10%. Có thể thấy các mẫu Known tập trung ở vùng GEN thấp (phân phối nhọn), trong khi Unknown bị đẩy về vùng GEN cao.




Hình 4.2: Biểu diễn t-SNE của 10.000 mẫu test CIFAR-100. (a) Màu sắc thể hiện ground-truth (Known vs Unknown). (b) Màu sắc thể hiện phân vùng cụm bởi thuật toán SNC. SNC phân cụm các Known classes rất tốt và bảo toàn cấu trúc của Unknown classes.




Hình 4.3: Phân phối Cluster Purity trên 100 clusters của CIFAR-100. Phần lớn các cụm có độ tinh khiết rất cao ($> 80\%$), chứng tỏ thuật toán ghép cặp (Hungarian matching) hoạt động trên các cụm đồng nhất.

4.5.1 Phân tích Trường hợp Thất bại

Để hiểu rõ hơn các lỗi còn lại của GESNC trên CIFAR-100, luận văn phân tích các lớp Unknown bị nhầm sang Known. Kết quả cho thấy lỗi tập trung ở các cặp có tương đồng ngữ nghĩa hoặc hình thái cao.



Hình 4.4: Mã trận nhầm lẫn giữa 20 lớp Unknown và 25 lớp Known bị nhầm nhiều nhất.



Hình 4.5: Độ chính xác theo từng lớp Unknown trên CIFAR-100.

Các cặp nhầm lẫn lớn nhất gồm streetcar → bus (86.60%), whale → dolphin (77.40%), woman → girl (70.20%), willow_tree → oak_tree (47.20%), và willow_tree → maple_tree (39.60%). Ba lớp Unknown khó nhất là streetcar, willow_tree và woman,

đều đạt 0.00% ACC trong báo cáo phân tích lỗi.

Không đủ thông tin để kết luận về các ví dụ ảnh cụ thể hoặc các trường hợp cluster collapse, vì các file kết quả hiện tại chưa cung cấp cluster assignments và danh sách mẫu ảnh theo từng lỗi.

4.6 Thảo luận

4.6.1 Vai trò của React trong GEN Pseudo-labeling

Trong các kết quả CIFAR-100 mới, cấu hình single-run tốt nhất sử dụng React [11] với $q = 0.99$ cùng PCT=10, $M = 16$ và $\gamma = 0.05$. Tuy nhiên, như đã nêu ở Mục 4.3.2, các file kết quả hiện tại không cung cấp so sánh cặp đôi giữa cùng một cấu hình có và không có React. Vì vậy, luận văn không kết luận rằng React là nguyên nhân độc lập tạo ra toàn bộ cải thiện quan sát được.

Về mặt cơ chế, React vẫn là một lựa chọn hợp lý để giảm overconfidence của linear head trên các mẫu Unknown: activation units được clip tại $c = Q_{0.99}$,

$$\tilde{h}(x) = \min(h(x), c).$$

Việc truncate các activation ngoại lai có thể làm phẳng phân phối softmax và giúp GEN score phản ánh tốt hơn độ bất định của mẫu. Tuy nhiên, từ ba file kết quả hiện có, không đủ thông tin để định lượng riêng đóng góp của React so với các thành phần còn lại của pipeline.

4.6.2 Trade-off Old/New ACC và Hành vi PCT

Trên CIFAR-100, PCT sweep mới ở Bảng 4.8 cho thấy PCT=10 đạt All ACC, New ACC và H-score cao nhất trong các giá trị được khảo sát. Khi PCT tăng lên 15, hiệu năng giảm

rõ; khi tăng đến 20, kết quả phục hồi gần mức tốt nhất nhưng vẫn không vượt $PCT=10$. Vì vậy, hành vi của PCT trong kết quả mới không nên được mô tả như một xu hướng đơn điệu.

Về mặt trực giác, PCT điều khiển số pseudo-label anchors được đưa vào SNC. PCT quá thấp có thể chưa tận dụng đủ các mẫu tin cậy, trong khi PCT quá cao có thể đưa thêm các mẫu Unknown bị classifier thiên vị sang Known class vào anchor pool. H-score như harmonic mean giữa Old ACC và New ACC giúp phản ánh sự cân bằng này tốt hơn All ACC đơn lẻ. Do đó, kết luận thực hành là **PCT nên được chọn dựa trên H-score hoặc validation trade-off Old/New ACC, không chỉ dựa trên All ACC.**

4.6.3 Khoảng cách CIFAR-100 và CUB-200

GESNC đạt 84.97% All ACC (kết quả single-run tốt nhất) trên CIFAR-100 nhưng chỉ 59.26% trên CUB-200 — khoảng cách 25.71%. Ba lý do chính:

(i) *Độ khó bài toán*: CUB-200 là fine-grained recognition benchmark với sự khác biệt hình ảnh giữa các loài rất nhỏ. Các phương pháp GCD tốt nhất cũng chỉ báo cáo 50–65% trên CUB-200.

(ii) *Dataset nhỏ*: CUB-200 chỉ có $\sim 6k$ training samples, dẫn đến chỉ ~ 1.500 labeled anchors — ít hơn 13 lần CIFAR-100. SNC cần đủ anchors để must-link/cannot-link constraints có tác dụng toàn cục.

(iii) *Tỉ lệ Unknown cao*: CUB-200 có 50% Unknown classes (100/200) so với 20% (20/100) của CIFAR-100. Classifier bias về Known class do đó ảnh hưởng nặng hơn đến New ACC.

4.6.4 Giới hạn và Hướng Cải thiện

Oracle K. $K = 100$ (CIFAR-100) và $K = 200$ (CUB-200) được cung cấp sẵn — giả định không thực tế trong open-world deployment. Thay thế bằng Silhouette-based Auto-K là hướng phát triển ưu tiên (xem Chương 5).

Phụ thuộc calibration của linear head. Khi linear head kém (ít epochs hoặc ít dữ liệu labeled), GEN filtering không hiệu quả ngay cả với React. Hướng cải thiện: kết hợp temperature scaling hoặc label smoothing để calibrate head tốt hơn trước khi tính GEN score.

Chi phí tính toán $O(n_{\text{anchor}}^2)$. Bước `req_numclust()` tính pairwise distance trên anchor pool: với 23.513 anchors CIFAR-100: $23513^2 \times 4 \approx 2.2$ GB RAM. Bottleneck này cần được giải quyết khi mở rộng sang dataset lớn hơn bằng anchor subsampling hoặc hierarchical merge.

CHƯƠNG 5

Kết luận và Hướng Phát triển

5.1 Tóm tắt Đóng góp

Luận văn này đề xuất **GESNC** (GEN-Augmented Semi-Supervised SNC) — một pipeline mới cho bài toán Generalized Category Discovery kết hợp ba thành phần kỹ thuật chính: (i) cổng entropy tổng quát GEN [10] để phân tách Known/Unknown, (ii) cơ chế calibration dựa trên React feature clipping [11] trong cấu hình single-run tốt nhất, và (iii) SNC semi-supervised [8] với dual-anchor pool (nhãn thật + pseudo-labels).

Phương pháp được thực nghiệm trên hai benchmark chuẩn và đạt các kết quả sau:

Trên CIFAR-100, kết quả single-run tốt nhất trong grid search mới với cấu hình $M = 16$, $\gamma = 0.05$, PCT=10 và React $q = 0.99$:

- All ACC = **84.97%**
- Old ACC = **85.69%**
- New ACC = **83.53%**
- H-score = **84.59%**

Kết quả này cho thấy cấu hình GESNC tốt nhất trong grid search có thể đạt hiệu

năng single-run cạnh tranh trên CIFAR-100. Tuy nhiên, vai trò riêng của React không được tách thành một kết luận ablation độc lập do thiếu so sánh cặp đôi có/không React trong cùng điều kiện ở bộ kết quả mới.

Trên CUB-200-2011, mô hình đạt All ACC = **59.26%** và H-score = **60.20%** trong cấu hình strict train-only tốt nhất ($M = 8$, $\gamma = 0.1$, PCT=5, no React). Đồng thời, đánh giá đa hạt giống (multi-seed) trên protocol transductive ghi nhận:

- All ACC = **58.92%** $\pm$ **0.12%** (tăng +0.42% so với baseline reproduction, $p = 0.0275$)
- Old ACC = **70.40%** $\pm$ **0.37%** (tăng +1.07%, $p = 0.0381$)
- New ACC = **53.17%** $\pm$ **0.00%** (tăng +0.10%, $p < 0.001$)
- H-score = **60.59%** $\pm$ **0.14%** (tăng +0.46%, $p = 0.0283$)

Dưới đây là phân tích ý nghĩa của từng đóng góp kỹ thuật:

Đóng góp 1 — Baseline reproduction và kiểm chứng pipeline. Trong cấu hình PCT=0 và React=False, pipeline được dùng như baseline reproduction của CiPR. Việc cấu hình này cho kết quả trùng khớp với mã nguồn CiPR gốc giúp kiểm tra tính đúng đắn của pipeline trước khi bổ sung GEN và React.

Đóng góp 2 — Phân tích trade-off Known–Unknown của GEN/PCT. Luận văn khảo sát ảnh hưởng của PCT và grid search M , γ trên CIFAR-100 bằng các kết quả single-run mới. Các kết quả này cho thấy PCT=10 đạt cân bằng tốt nhất giữa New ACC và H-score trong grid hiện có, trong khi đánh giá đa hạt giống cho thấy lợi ích trên New ACC cần được diễn giải thận trọng do chưa đạt ý nghĩa thống kê.

Đóng góp 3 — Transductive Inference trên 60k mẫu. Chạy SNC trên 60k mẫu

(train + test gộp) thay vì chỉ train giúp khai thác global cluster structure và có kết nối first-neighbor tốt hơn khi có context của toàn bộ dataset.

Đóng góp 4 — Adaptive GEN Gate với Calibrated Parameters. Qua grid search hệ thống trên $M \in \{4, 8, 16\}$ và $\gamma \in \{0.05, 0.10, 0.20\}$, luận văn xác định $M = 16$, $\gamma = 0.05$ là cấu hình single-run tốt nhất cho CIFAR-100. Tuy nhiên, các cấu hình lân cận cho kết quả rất gần nhau, nên luận văn không diễn giải khác biệt này như một kết luận thống kê mạnh.

5.2 Hạn chế

Mặc dù đạt kết quả single-run cạnh tranh trên CIFAR-100, GESNC vẫn có bốn hạn chế quan trọng cần được thừa nhận trung thực:

(1) Oracle K. $K = 100$ (CIFAR-100) và $K = 200$ (CUB-200) được biết trước — giả định không thực tế trong môi trường open-world thực sự. Đây là hạn chế nghiêm trọng nhất, ảnh hưởng đến tính áp dụng của phương pháp trong triển khai thực tế.

(2) Chưa tách riêng được đóng góp của React. Trong bộ kết quả mới, cấu hình tốt nhất trên CIFAR-100 có sử dụng React, nhưng chưa có so sánh cặp đôi với cấu hình không React dưới cùng M , γ , PCT và protocol. Vì vậy, luận văn không kết luận độc lập về mức đóng góp của React. Pipeline vẫn có các hyperparameter bổ sung (q của React, PCT của GEN) cần được tuning — làm tăng độ phức tạp so với CiPR.

(3) Khoảng cách lớn trên CUB-200. All ACC 59.26% trên CUB-200 thấp hơn 25.56% so với CIFAR-100. Pipeline hiện tại chưa được tối ưu cho fine-grained recognition với dataset nhỏ. Số lượng anchors ít (~ 1.500) giới hạn hiệu quả của must-link/cannot-link constraints trong SNC.

(4) Chi phí tính toán $O(n^2)$. Bước pairwise distance trong `req_numclust()` với

23.513 anchors CIFAR-100 tốn ~ 2.2 GB RAM. Bottleneck này không cho phép mở rộng sang dataset lớn hơn (ví dụ: ImageNet-100 với 500k samples) mà không có kỹ thuật approximate nearest neighbor bổ sung.

5.3 Hướng Phát triển Tương lai

5.3.1 Ưu tiên 1 — Auto-K: Ước lượng Số Cluster Tự động

Hạn chế Oracle K là khoảng trống lớn nhất cần lấp đầy. Hướng đề xuất là kết hợp Silhouette Score với SNC hierarchy:

$$K^* = \arg \max_{K \in [K_{\min}, K_{\max}]} \frac{1}{N} \sum_{i=1}^N s(i; K) \quad (5.1)$$

trong đó $s(i; K)$ là Silhouette coefficient của điểm i khi có K clusters. Quy trình: chạy SNC với dải K từ $K_{\min} = |\mathcal{C}^{\text{old}}|$ đến $K_{\max} = 3|\mathcal{C}^{\text{old}}|$, tính Silhouette trên validation features, chọn K^* tối ưu.

Thách thức cần giải quyết: Silhouette Score bị ảnh hưởng bởi cluster size imbalance (Known clusters lớn hơn Unknown), cần weighting scheme phù hợp.

5.3.2 Ưu tiên 2 — Iterative Pseudo-label Refinement

Pipeline hiện tại chạy một lần (one-shot): Linear Head $\rightarrow$ GEN Gate $\rightarrow$ SNC. Hướng cải thiện: vòng lặp Expectation-Maximization:

1. **E-step:** SNC cluster assignments $\rightarrow$ cập nhật pseudo-labels dựa trên cluster majority vote.
2. **M-step:** Re-compute GEN gate với pseudo-labels mới, cập nhật anchor pool.

3. Lặp đến hội tụ (thường 2–3 vòng).

Mỗi vòng, chất lượng pseudo-labels tăng lên khi SNC có thêm thông tin clustering — tạo vòng phản hồi tích cực.

5.3.3 Ưu tiên 3 — Mở rộng sang Dataset Lớn hơn

Để tăng tính thuyết phục của kết quả, luận văn cần được kiểm nghiệm trên các benchmark GCD khác: **Stanford Cars** [26] (196 classes), **ImageNet-100** [27] (100 classes, ~130k ảnh), và **Herbarium 19** [28] (683 classes, rất fine-grained). Với ImageNet-100, cần thay thế exact pairwise distance bằng PyNNDescent ANN để tránh OOM.

5.3.4 Ưu tiên 4 — Memory-Efficient SNC

Thay pairwise distance $O(n^2)$ trong `req_numclust()` bằng hierarchical merging với ANN:

- Chia anchor pool thành mini-batches.
- Merge in-batch trước, sau đó merge across batches.
- Giảm memory từ $O(n^2)$ xuống $O(n \log n)$.

Hoặc: subsample anchor pool xuống $n' \ll n$ trước khi chạy `req_numclust()`, với xác suất sampling tỉ lệ nghịch với cluster size.

5.3.5 Ưu tiên 5 — Backbone Fine-tuning Aware của GCD

Backbone DINO hiện bị freeze hoàn toàn. Một hướng mở rộng là tinh chỉnh nhẹ (low-rank fine-tuning / LoRA) backbone với loss kết hợp supervised Known + unsupervised Unknown:

$$\mathcal{L} = \mathcal{L}_{\text{sup}}(\mathcal{D}_l) + \lambda \cdot \mathcal{L}_{\text{unsup}}(\mathcal{D}_u)$$

Tuy nhiên cần cẩn thận với catastrophic forgetting: fine-tuning quá mạnh có thể phá vỡ geometric properties của DINO features vốn là nền tảng của SNC.

5.4 Kết luận

Luận văn đã trình bày GESNC, một pipeline Generalized Category Discovery mới kết hợp ba yếu tố: SNC semi-supervised với labeled anchors, GEN entropy gate, calibration trong cấu hình tốt nhất, và transductive inference trên toàn bộ dataset.

Trên CIFAR-100, kết quả single-run tốt nhất trong grid search mới đạt All ACC = 84.97%, Old ACC = 85.69%, New ACC = 83.53%, và H-score = 84.59%. Tuy nhiên, đánh giá đa hạt giống cho thấy cải thiện của GESNC không đồng đều trên toàn bộ chỉ số. So với baseline reproduction của CiPR, GESNC tăng New ACC nhẹ nhưng giảm Old ACC, All ACC và H-score. Do đó, kết luận chính của luận văn không phải là GESNC đạt ưu thế tuyệt đối, mà là phương pháp này cung cấp một cơ chế OOD-aware để điều chỉnh trade-off giữa Known và Unknown classes.

Trên CUB-200-2011 với backbone fine-tuned 200 epochs, mô hình đạt All ACC = 59.26% và H-score = 60.20%, cho thấy pipeline khả thi trên fine-grained benchmark nhưng còn dư địa cải thiện đáng kể, đặc biệt về số lượng labeled anchors và Auto-K estimation.

Hai đóng góp học thuật chính của luận văn là: (i) kiểm chứng baseline reproduction của CiPR trong cùng pipeline đánh giá, và (ii) phân tích trade-off Known–Unknown khi GEN/PCT được tích hợp vào SNC. Chúng tôi hy vọng những phát hiện này sẽ là điểm khởi đầu cho các nghiên cứu tiếp theo về OOD-aware clustering trong Open-World Learning.

Tài liệu tham khảo

- [1] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
address: <http://www.deeplearningbook.org>.
- [2] Y. LeCun, Y. Bengio, and G. Hinton, “Deep Learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [3] K. Han, A. Vedaldi, and A. Zisserman, “Learning to Discover Novel Visual Categories via Deep Transfer Clustering,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 8401–8409.
- [4] S. Vaze, K. Han, A. Vedaldi, and A. Zisserman, “Generalized Category Discovery,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 7492–7501.
- [5] X. Wen, B. Zhao, and X. Qi, “Parametric Classification for Generalized Category Discovery: A Baseline Study,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.
- [6] S. Vaze, A. Vedaldi, and A. Zisserman, “No Representation Rules Them All in Category Discovery,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [7] B. Zhao and K. Han, “Learning Semi-supervised Gaussian Mixture Models for Generalized Category Discovery,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.
- [8] S. Hao, K. Han, and K.-Y. K. Wong, “CiPR: An Efficient Framework with Cross-instance Positive Relations for Generalized Category Discovery,” *Transactions on Machine Learning Research (TMLR)*, 2024.

- [9] D. Hendrycks and K. Gimpel, “A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks,” in *International Conference on Learning Representations (ICLR)*, 2017.
- [10] X. Liu, Y. Lochman, and C. Zach, “GEN: Pushing the Limits of Softmax-Based Out-of-Distribution Detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 23 946–23 955.
- [11] Y. Sun, C. Guo, and Y. Li, “ReAct: Out-of-distribution Detection With Rectified Activations,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021, pp. 144–157.
- [12] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, “A Simple Framework for Contrastive Learning of Visual Representations,” in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020, pp. 1597–1607.
- [13] K. He, H. Fan, Y. Wu, S. Xie, and R. Girshick, “Momentum Contrast for Unsupervised Visual Representation Learning,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 9729–9738.
- [14] J.-B. Grill et al., “Bootstrap Your Own Latent: A New Approach to Self-Supervised Learning,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 21 271–21 284, 2020.
- [15] M. Caron et al., “Emerging Properties in Self-Supervised Vision Transformers,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 9650–9660.
- [16] A. Dosovitskiy et al., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” in *International Conference on Learning Representations (ICLR)*, 2021.
- [17] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [18] W. Liu, X. Wang, J. Owens, and Y. Li, “Energy-Based Out-of-Distribution Detection,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 21 464–21 475.

- [19] S. Basu, M. Bilenko, and R. J. Mooney, “A Probabilistic Framework for Semi-Supervised Clustering,” pp. 59–68, 2004.
- [20] K. Wagstaff, C. Cardie, S. Rogers, and S. Schrödl, “Constrained K-means Clustering with Background Knowledge,” pp. 577–584, 2001.
- [21] D.-H. Lee, “Pseudo-Label: The Simple and Efficient Semi-Supervised Learning Method for Deep Neural Networks,” *Workshop on Challenges in Representation Learning, ICML*, vol. 3, no. 2, 2013.
- [22] K. Sohn et al., “FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 596–608.
- [23] H. W. Kuhn, “The Hungarian Method for the Assignment Problem,” *Naval Research Logistics Quarterly*, vol. 2, no. 1–2, pp. 83–97, 1955.
- [24] A. Krizhevsky, “Learning Multiple Layers of Features from Tiny Images,” University of Toronto, tech. rep., 2009.
- [25] C. Wah, S. Branson, P. Welinder, P. Perona, and S. Belongie, “The Caltech-UCSD Birds-200-2011 Dataset,” California Institute of Technology, tech. rep. CNS-TR-2011-001, 2011.
- [26] J. Krause, M. Stark, J. Deng, and L. Fei-Fei, “3D Object Representations for Fine-Grained Categorization,” in *4th IEEE Workshop on 3D Representation and Recognition*, 2013.
- [27] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “ImageNet: A Large-Scale Hierarchical Image Database,” 2009.
- [28] K. C. Tan, Y. Liu, B. Ambrose, M. Tulig, and S. Belongie, “The Herbarium Challenge 2019 Dataset,” in *FGVC6 Workshop, CVPR*, 2019.

PHỤ LỤC A

Mã nguồn Pipeline GCD_GESNC

Toàn bộ mã nguồn triển khai thực nghiệm của pipeline GCD_GESNC được lưu trữ công khai trên GitHub. Hội đồng và người đọc có thể truy cập, tham khảo và tái lập kết quả tại địa chỉ:

https://github.com/Yato742003/GCD_GESNC

Cấu trúc thư mục dự án:

GCD_GESNC/	
src/	— Mã nguồn cốt lõi
models/	
vision_transformer.py	— ViT-B/16 DINO backbone
snc/	
clustering.py	— Thuật toán SNC semi-supervised, dual-anchor pool
snc_wrapper.py	— Wrapper tích hợp SNC vào pipeline
utils/	
gen_entropy.py	— Tính GEN score, React clipping, adaptive threshold
metrics.py	— All/Old/New ACC, H-score, Hungarian matching
pipeline/	— Kết nối các module thành pipeline hoàn chỉnh
main_eval.py	— Script đánh giá chính (CIFAR-100)
eval_cub_gesnc.py	— Script đánh giá CUB-200-2011
extract_features.py	— Trích xuất CLS token từ DINO

<code>ablation_cifar_full.sh</code>	— Kịch bản ablation study đầy đủ
<code>ablation_m_gamma.sh</code>	— Kịch bản grid search M và γ
<code>dataset_cub200.py</code>	— Xử lý và split CUB-200-2011
<code>checkpoints/</code>	— Weights Linear Head đã huấn luyện
<code>data/</code>	— Thư mục dữ liệu (CIFAR-100, CUB-200)
<code>features/</code>	— Cache CLS token features
<code>requirements.txt</code>	— Danh sách thư viện Python
<code>results/</code>	— kết quả thử nghiệm và minh chứng
<code>README.md</code>	— Hướng dẫn cài đặt và tái lập kết quả